Centro Paula Souza

Faculdade de Tecnologia de Votorantim

Curso de Ciência de Dados para Negócios

Projeto Integrador III – Análise de Dados I

Eduardo Morelato

Eric Rordigues Berto

Giovana Lacerda Machado

Luiz Gustavo Machado

Michel Cirilo de Oliveira

Jun/2025

AUTOMAÇÃO DO PROCESSO DE ANÁLISE DO PLANO DE GESTÃO ANUAL (PGA) DAS FACULDADES DE TECNOLOGIA: UMA PROPOSTA DE PIPELINE DE DADOS BASEADO EM PYTHON

Curso: Tecnologia em Ciência de Dados para Negócios
Instituição: Faculdade de Tecnologia de Votorantim - Centro Paula Souza
Regional: NRA 11 - Sorocaba
Período: Projeto Integrador 3 (Maio-Junho 2025)

RESUMO

O presente trabalho propõe o desenvolvimento de um sistema automatizado para análise dos dados contidos nos Planos de Gestão Anual (PGA) das Faculdades de Tecnologia do Centro Paula Souza. A proposta surge da necessidade de transformar dados não estruturados, disponibilizados em formato PDF, em informações estratégicas estruturadas e visualizáveis através de dashboards interativos. O projeto utiliza exclusivamente tecnologias Python para implementar um pipeline completo de ETL (Extract, Transform, Load), seguindo os princípios da modelagem dimensional tipo Snowflake. Os indicadores-chave identificados incluem carga horária por projeto, priorização de iniciativas, contagem de projetos por categoria e checklist de conformidade. A solução proposta visa otimizar o processo de tomada de decisão estratégica nas 75 Fatecs do sistema, iniciando pela Regional 11 - Sorocaba, que compreende sete unidades. A metodologia adotada baseia-se em práticas consolidadas de ciência de dados e engenharia de software, garantindo escalabilidade, manutenibilidade e reprodutibilidade dos resultados.

Palavras-chave: Automação de Processos, ETL, Business Intelligence, Análise de Dados, Gestão Educacional.

---

1. INTRODUÇÃO

1.1 Contextualização do Problema

O Centro Paula Souza (CPS), autarquia vinculada à Secretaria de Ciência, Tecnologia e Inovação do Estado de São Paulo, representa uma das maiores redes de educação profissional do Brasil. Reconhecido em 2024 como Instituto de Ciência e Tecnologia (ICT) pelo Conselho das Instituições de Pesquisa do Estado de São Paulo (Consip), o CPS administra um complexo sistema educacional que abrange 223 Escolas Técnicas Estaduais (Etecs) e 75 Faculdades de Tecnologia (Fatecs), distribuídas em aproximadamente 360 municípios paulistas, atendendo mais de 322 mil estudantes.

A gestão estratégica desta rede educacional de grande porte demanda instrumentos de planejamento e controle adequados à sua complexidade operacional. Neste contexto, o Plano

de Gestão Anual (PGA) constitui-se como ferramenta fundamental para o direcionamento das atividades acadêmicas e administrativas das Fatecs. O PGA integra-se ao Plano Plurianual de Gestão (PPG), com vigência quinquenal, estabelecendo um sistema de planejamento estratégico hierarquizado que garante alinhamento entre objetivos institucionais e execução operacional.

1.2 Estrutura Organizacional e Regional

O CPS implementou em 2018 um Projeto de Regionalização, organizando suas unidades em 12 Núcleos Regionais de Administração (NRAs). Esta estrutura visa proporcionar maior proximidade com as Unidades de Ensino através de métodos dinâmicos, considerando as diversas realidades regionais do Estado de São Paulo. Cada NRA utiliza espaços físicos já consolidados pela Supervisão Pedagógica Regional das Etecs, otimizando recursos e facilitando a coordenação administrativa.

A Regional 11 - Sorocaba, foco deste estudo, compreende sete Faculdades de Tecnologia estrategicamente distribuídas na região: Fatec Botucatu, Fatec Itapetininga, Fatec Itu, Fatec São Roque, Fatec Sorocaba, Fatec Tatuí e Fatec Votorantim. Esta regionalização não apenas facilita a gestão administrativa, mas também permite análises comparativas e benchmarking entre unidades com características socioeconômicas similares.

1.3 Fatec Votorantim e o Curso de Ciência de Dados

A Fatec Votorantim destaca-se no cenário educacional regional pela oferta do curso de Tecnologia em Ciência de Dados para Negócios, lançado em 2024. Este curso representa uma resposta estratégica às demandas do mercado de trabalho contemporâneo, caracterizado pela crescente necessidade de profissionais capacitados para extrair insights acionáveis de grandes volumes de dados.

O curso alinha competências técnicas em programação, estatística e machine learning com conhecimentos de negócios, formando profissionais capazes de traduzir problemas empresariais em soluções baseadas em dados. Esta formação híbrida posiciona os egressos como agentes de transformação digital nas organizações, capazes de implementar soluções de Business Intelligence e Analytics.

1.4 Justificativa e Relevância

A análise manual dos dados contidos nos PGAs representa um gargalo operacional significativo no processo de gestão estratégica das Fatecs. Os documentos, tradicionalmente disponibilizados em formato PDF, contêm informações valiosas sobre projetos, alocação de recursos, cronogramas e indicadores de performance, mas sua estrutura não padronizada dificulta a extração sistemática de insights.

Este cenário evidencia uma oportunidade de aplicação prática dos conhecimentos adquiridos no curso de Ciência de Dados para Negócios, ao mesmo tempo em que se propõe uma

solução concreta para um problema institucional real. A automação do processo de análise dos PGAs contribuirá para:

- **Eficiência Operacional**: Redução significativa do tempo necessário para processamento e análise dos dados;
- **Padronização**: Estabelecimento de critérios uniformes de análise e comparação entre unidades;
- **Transparência**: Maior visibilidade dos indicadores de gestão para stakeholders internos e externos;
- **Tomada de Decisão**: Disponibilização de informações estruturadas para apoio ao processo decisório estratégico.

---

2. REFERENCIAL TEÓRICO

2.1 Fundamentos de Business Intelligence em Instituições Educacionais

O conceito de Business Intelligence (BI) em instituições educacionais tem evoluído significativamente nas últimas décadas, impulsionado pela necessidade de gestão baseada em evidências e accountability educacional. Segundo Kimball e Ross (2013), a implementação de sistemas de BI em organizações complexas requer abordagem metodológica rigorosa, considerando tanto aspectos técnicos quanto organizacionais.

No contexto educacional, o BI assume características específicas, pois lida com dados de natureza diversa: acadêmica, administrativa, financeira e social. A integração destes diferentes tipos de informação permite uma visão holística da instituição, facilitando a identificação de padrões, tendências e oportunidades de melhoria.

2.2 Modelagem Dimensional e Arquitetura Snowflake

A modelagem dimensional, proposta inicialmente por Kimball (1996), constitui-se como abordagem fundamental para estruturação de Data Warehouses. Entre os modelos dimensionais, o esquema Snowflake destaca-se pela normalização das tabelas de dimensão, resultando em maior integridade referencial e redução de redundâncias.

O modelo Snowflake é caracterizado por:

- **Tabela Fato Central**: Contém as métricas quantitativas e chaves estrangeiras para as dimensões;
- **Tabelas de Dimensão Normalizadas**: Subdivididas em hierarquias que eliminam redundâncias;
- **Relacionamentos Complexos**: Estrutura ramificada que lembra um floco de neve.

Vantagens do Modelo Snowflake:

- Menor redundância de dados, resultando em economia de espaço de armazenamento;
- Maior integridade referencial através da normalização;
- Facilita a manutenção e atualização de dados mestres;
- Escalabilidade para grandes volumes de dados.

Desvantagens:

- Maior complexidade nas consultas devido aos múltiplos joins necessários;
- Possível impacto na performance para consultas analíticas frequentes;
- Curva de aprendizado mais acentuada para usuários finais.

2.3 Processamento de Documentos Não Estruturados

O processamento de documentos em formato PDF apresenta desafios técnicos específicos, relacionados à diversidade de formatos, qualidade de digitalização e estruturas de layout. A literatura especializada identifica três abordagens principais:

1. **Extração Baseada em Texto**: Adequada para PDFs nativos com texto selecionável;
2. **Reconhecimento Óptico de Caracteres (OCR)**: Necessário para documentos escaneados;
3. **Processamento Híbrido**: Combinação das abordagens anteriores com validação cruzada.

2.4 Tecnologias Python para Ciência de Dados

O ecossistema Python oferece um conjunto robusto de bibliotecas especializadas para cada etapa do pipeline de dados:

Para Extração de Dados:

- **PyMuPDF**: Biblioteca de alto desempenho para manipulação de PDFs;
- **pdfplumber**: Especializada em extração de tabelas e estruturas complexas;
- **pytesseract**: Interface Python para o motor OCR Tesseract.

Para Processamento e Análise:

- **pandas**: Manipulação e análise de estruturas de dados;
- **NumPy**: Computação numérica e operações matriciais;
- **scikit-learn**: Algoritmos de machine learning e pré-processamento.

Para Visualização:

- **Streamlit**: Framework para criação de aplicações web de dados;

- **Plotly**: Biblioteca para gráficos interativos;
- **matplotlib/seaborn**: Visualizações estáticas de alta qualidade.

A organização dessas bibliotecas ao longo do pipeline pode ser visualizada na Figura 1.

3. METODOLOGIA

3.1 Classificação da Pesquisa

Este trabalho caracteriza-se como pesquisa aplicada de natureza quantitativa e qualitativa, com abordagem de desenvolvimento tecnológico. A metodologia adotada baseia-se nos princípios da Design Science Research (DSR), que visa criar e avaliar artefatos tecnológicos para resolver problemas práticos identificados.

3.2 Objeto de Estudo

O objeto de estudo compreende os Planos de Gestão Anual (PGA) das sete Faculdades de Tecnologia pertencentes à Regional 11 - Sorocaba do Centro Paula Souza.

3.3 Metodologia de Desenvolvimento

O desenvolvimento seguirá a metodologia ágil adaptada para projetos de ciência de dados.

Fase 1: Business Understanding

- Compreensão detalhada do contexto institucional;
- Identificação dos stakeholders e suas necessidades;
- Definição dos objetivos de negócio e critérios de sucesso.

Fase 2: Data Understanding

- Análise exploratória dos documentos PGA;
- Identificação de padrões e estruturas recorrentes;
- Avaliação da qualidade e completude dos dados.

Fase 3: Data Preparation

- Desenvolvimento de rotinas de extração automatizada;
- Implementação de processos de limpeza e normalização;
- Criação de estruturas de dados padronizadas.

Fase 4: Modeling

- Implementação do modelo dimensional Snowflake;
- Desenvolvimento de algoritmos de classificação e categorização;
- Criação de métricas e indicadores derivados.

Fase 5: Evaluation

- Validação dos resultados com especialistas de domínio;
- Testes de performance e escalabilidade;
- Avaliação da usabilidade dos dashboards.

Fase 6: Deployment

- Implementação do sistema em ambiente de produção;
- Treinamento dos usuários finais;
- Documentação técnica e operacional.

3.4 Coleta e Análise de Dados

A coleta de dados será realizada através de:

- **Análise documental**: Exame sistemático dos PGAs em formato PDF;
- **Entrevistas semiestruturadas**: Com gestores e coordenadores das Fatecs;
- **Observação participante**: Durante o processo de planejamento anual;
- **Validação cruzada**: Comparação entre dados extraídos e fontes oficiais.

---

4. PROPOSTA DE SOLUÇÃO

4.1 Arquitetura Geral do Sistema

A solução proposta é estruturada sobre uma arquitetura modular de pipeline de dados, desenvolvida em Python. Essa arquitetura adota o paradigma ETL (Extract, Transform, Load), expandido com etapas adicionais voltadas à análise e visualização de dados. O processo tem início com a ingestão de documentos no formato PDF, que contêm informações institucionais do PGA, e percorre as fases de extração textual (via PyMuPDF, pdfplumber e Tesseract OCR), transformação e limpeza de dados (utilizando pandas, NumPy e expressões regulares), até o carregamento em um banco de dados SQLite com suporte do SQLAlchemy ORM.

A fase final contempla a apresentação dos dados por meio de dashboards interativos implementados com Streamlit, visualizações gráficas com Plotly e mapas com Folium, tornando os resultados acessíveis e intuitivos para os usuários finais.

A Figura 1 ilustra o Pipeline de Processamento de Documentos Institucionais do PGA, destacando cada etapa e as respectivas tecnologias empregadas ao longo do fluxo de dados.

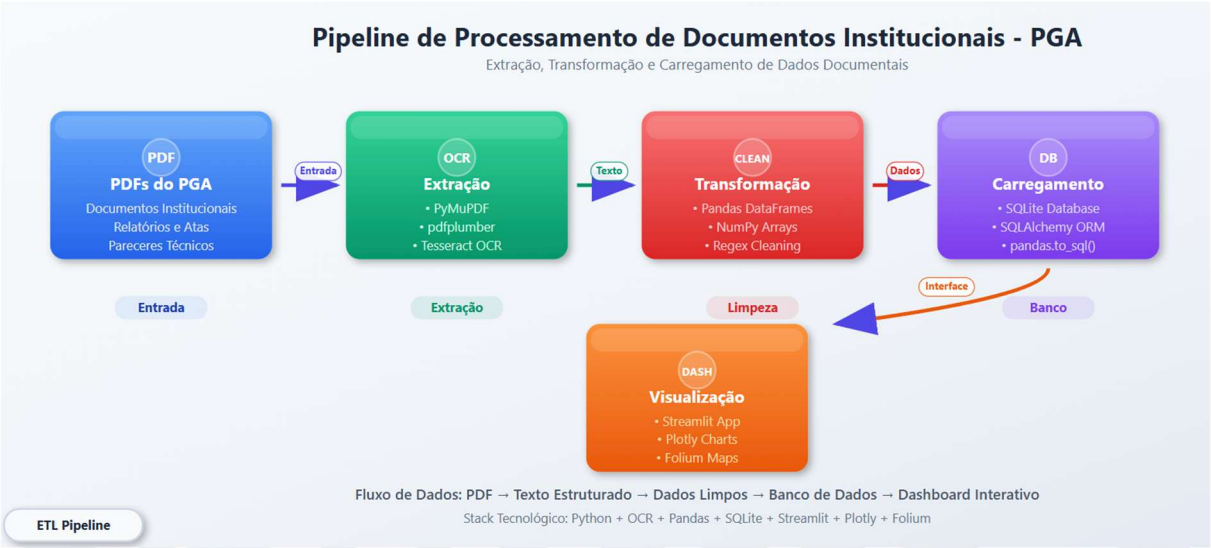


Figura 1 - Pipeline

4.2 Modelo Conceitual de Dados

O modelo de dados segue o esquema Snowflake, sendo otimizado para análises multidimensionais dos dados do PGA. As associações entre as entidades podem ser visualizadas na Figura 2, enquanto o modelo com os respectivos relacionamentos e chaves está representado na Figura 3.

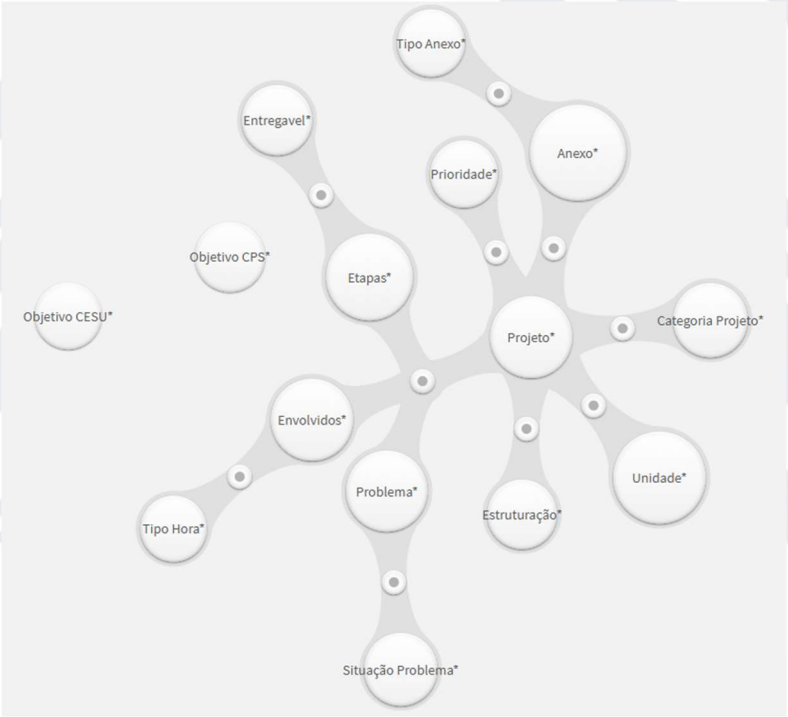


Figura 2 - Modelo Associativo

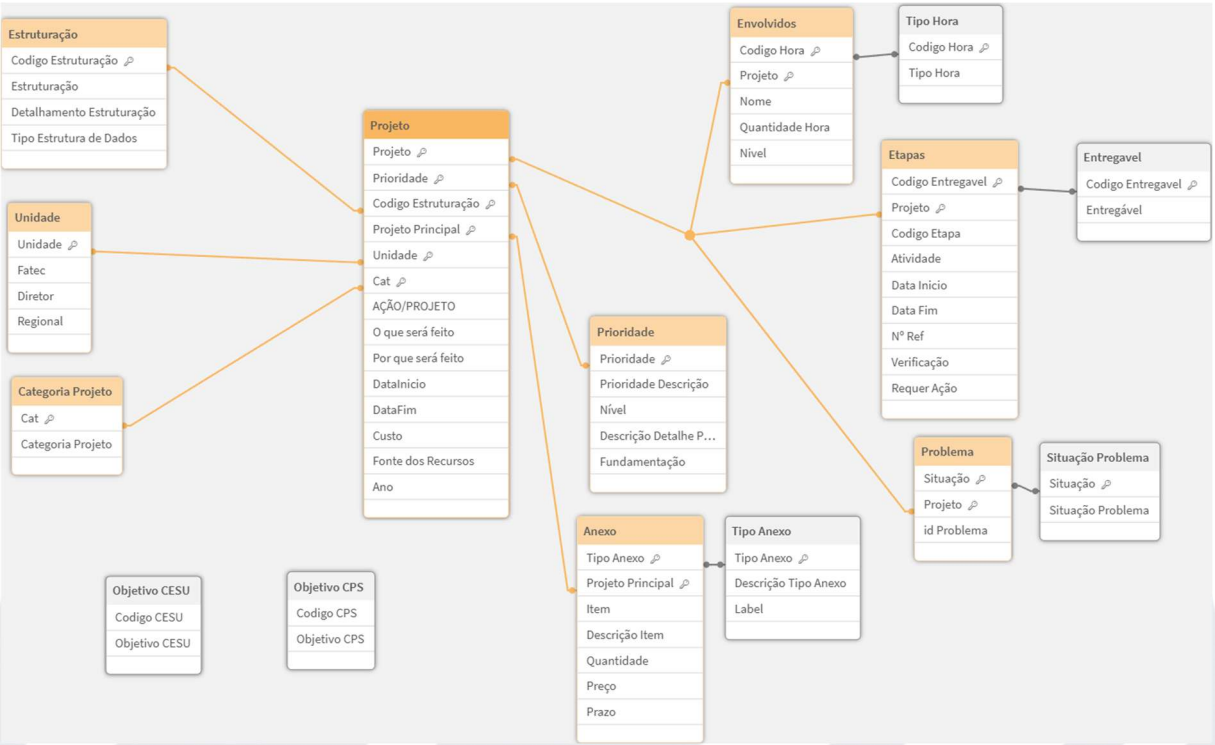


Figura 3 - Modelo Dimensional (snowflake)

A ilustração das tabelas, conforme apresentada na Figura 4, representa a estrutura do modelo dimensional adotado no projeto, com a Tabela Fato central “Projeto” conectando-se a múltiplas dimensões normalizadas.

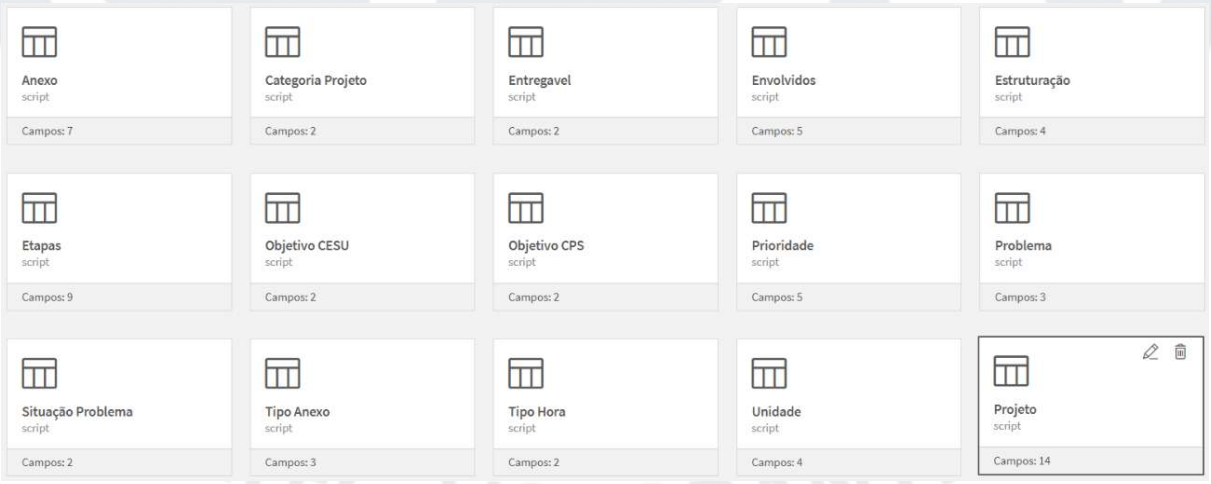


Figura 4 – Tabelas 14 Dimensões e 1 Fato

Tabela Fato Central:

1. **Projeto**

- **Chave Primária (PK):** Projeto
- **Chaves Estrangeiras (FK):**
  - Prioridade (referencia Prioridade)
  - Código Estruturação (referencia Estruturação)
  - Unidade (referencia Unidade)
  - Cat (referencia Categoria Projeto)
  - Projeto Principal (referencia Anexo)
- **Atributos:** Projeto Principal, AÇÃO PROJETO, O que será feito, Por que será feito, DataInicio, DataFim, Custo, Fonte dos Recursos, Ano

Dimensões Normalizadas:

1. **Estruturação**

- **Chave Primária (PK):** Código Estruturação
- **Atributos:** Detalhamento Estruturação, Tipo Estrutura de Dados

2. **Unidade**

- **Chave Primária (PK):** Unidade
- **Atributos:** Fatec, Diretor

3. **Categoria Projeto**

- **Chave Primária (PK):** Cat
- **Atributos:** Categoria Projeto

4. **Envolvidos**

- **Chave Primária (PK):** (Código Hora, Projeto) - *Provavelmente chave composta*
- **Chave Estrangeira (FK):** Projeto (referencia Projeto)
- **Atributos:** Nome, Quantidade Hora, Nível

5. **Tipo Hora**

- **Chave Primária (PK):** Tipo Hora
- **Atributos:** Tipo Hora (atributo adicional, parece redundante com a PK, ou representa a descrição do tipo)

6. **Etapas**

- **Chave Primária (PK):** (Código Entregável, Projeto, Código Etapa) - *Provavelmente chave composta*

- **Chave Estrangeira (FK):** Projeto (referencia Projeto)
- **Atributos:** Atividade, Data Início, Data Fim, Nº Ref, Verificação, Requer Ação

7. Entregavel

- **Chave Primária (PK):** Código Entregável
- **Atributos:** Entregavel (descrição do entregável)

8. Prioridade

- **Chave Primária (PK):** Prioridade
- **Atributos:** Prioridade Descrição, Nível, Descrição Detalhe P..., Fundamentação

9. Anexo

- **Chave Primária (PK):** Item
- **Chaves Estrangeiras (FK):**
  - Tipo Anexo (referencia Tipo Anexo)
  - Projeto Principal (referencia Projeto)
- **Atributos:** Descrição Item, Quantidade, Preço, Prazo

10. Tipo Anexo

- **Chave Primária (PK):** Tipo Anexo
- **Atributos:** Descrição Tipo Anexo, Label

11. Problema

- **Chave Primária (PK):** (Situação, Projeto, Id Problema) - *Provavelmente chave composta*
- **Chave Estrangeira (FK):** Projeto (referencia Projeto)
- **Atributos:** (nenhum atributo adicional listado além das chaves)

12. Situação Problema

- **Chave Primária (PK):** Situação
- **Atributos:** Situação Problema (descrição da situação)

13. Objetivo CESU

- **Chave Primária (PK):** Código CESU
- **Atributos:** Objetivo CESU

14. Objetivo CPS

- **Chave Primária (PK):** Código CPS
- **Atributos:** Objetivo CPS

4.3 Componentes do Sistema

4.3.1 Módulo de Extração (Extract)

Biblioteca Principal: PyMuPDF (fitz)

```
import fitz  # PyMuPDF
import pdfplumber
import pytesseract
from PIL import Image

class PGAExtractor:
    def __init__(self, pdf_path):
        self.pdf_path = pdf_path
        self.doc = fitz.open(pdf_path)

    def extract_structured_data(self):
        """
        Extrai dados estruturados do PDF do PGA
        """
        # Detecção automática de tipo de PDF
        # Extração via texto nativo ou OCR
        # Identificação de seções específicas
        # Processamento de tabelas e metadados
        Pass
```

Funcionalidades Implementadas:

- Detecção automática de PDFs nativos vs. escaneados
- Extração de texto com preservação de estrutura
- Reconhecimento de tabelas e formulários
- Processamento de metadados e propriedades do documento

4.3.2 Módulo de Transformação (Transform)

Biblioteca Principal: pandas

```
import pandas as pd
import numpy as np
import re
from dateutil import parser

class PGATransformer:
    def __init__(self, raw_data):
        self.raw_data = raw_data
```

```
    def clean_and_structure(self):
        """
        Limpa e estrutura dados extraídos
        """
        # Normalização de texto
        # Identificação de padrões com regex
        # Categorização automática de projetos
        # Cálculo de métricas derivadas
        Pass
```

Operações de Transformação:

- Limpeza e normalização de strings
- Parsing de datas e valores numéricos
- Categorização automática baseada em palavras-chave
- Validação de consistência e integridade
- Geração de métricas calculadas

4.3.3 Módulo de Carregamento (Load)

Biblioteca Principal: SQLAlchemy

```
from sqlalchemy import create_engine, MetaData, Table, Column
from sqlalchemy.orm import sessionmaker
import sqlite3

class PGADataLoader:
    def __init__(self, db_path):
        self.engine = create_engine(f'sqlite:///{db_path}')
        self.metadata = MetaData()

    def create_snowflake_schema(self):
        """
        Cria esquema dimensional Snowflake
        """
        # Definição de tabelas fato e dimensão
        # Criação de índices otimizados
        # Estabelecimento de relacionamentos
        Pass
```

4.3.4 Módulo de Visualização (Visualization)

Framework Principal: Streamlit

```
import streamlit as st
import plotly.express as px
import plotly.graph_objects as go
import folium
from streamlit_folium import folium_static

class PGADashboard:
    def __init__(self, data_source):
        self.data_source = data_source

    def render_main_dashboard(self):
        """
        Renderiza dashboard principal
        """
        # KPIs e métricas principais
        # Gráficos interativos
        # Filtros dinâmicos
        # Mapas geográficos
        Pass
```

4.4 Indicadores-Chave e Métricas Analíticas

4.4.1 Carga Horária por Projeto

Definição: Quantificação do esforço alocado em cada projeto do PGA, segmentado por categoria, prioridade e período de execução.

Métricas Derivadas:

- Distribuição percentual de horas por categoria de projeto
- Taxa de utilização de recursos humanos por unidade
- Variação temporal da alocação de esforços
- Comparativo inter-unidades de carga horária

Visualizações:

- Gráficos de barras empilhadas por categoria
- Heatmaps temporais de distribuição de esforço
- Treemaps hierárquicos de projetos e sub-projetos
- Séries temporais de evolução da carga horária

4.4.2 Priorização de Projetos

Definição: Classificação e quantificação dos projetos segundo critérios de prioridade estabelecidos pela instituição.

Métricas Derivadas:

- Distribuição percentual por nível de prioridade
- Correlação entre prioridade e alocação de recursos
- Taxa de conclusão por nível de prioridade
- Alinhamento estratégico dos projetos prioritários

Visualizações:

- Gráficos de rosca com distribuição de prioridades
- Scatter plots de prioridade vs. recursos alocados
- Dashboards de semáforo para projetos críticos
- Matriz de priorização bidimensional

4.4.3 Contagem e Categorização de Projetos

Definição: Quantificação e classificação dos projetos presentes nos PGAs, segmentados por seção, categoria temática e status de execução.

Métricas Derivadas:

- Total de projetos por Fatec e por categoria
- Taxa de projetos ativos vs. concluídos
- Distribuição por área de conhecimento
- Densidade de projetos por seção do PGA

Visualizações:

- Cards de métricas com totalizadores
- Gráficos de barras comparativos entre unidades
- Sunburst charts para hierarquia de categorias
- Tabelas dinâmicas com drill-down capabilities

4.4.4 Checklist de Conformidade

Definição: Avaliação sistemática da completude e consistência dos dados presentes nos PGAs, baseado em critérios pré-estabelecidos.

Métricas Derivadas:

- Taxa de conformidade geral por unidade
- Identificação de campos obrigatórios ausentes
- Consistência temporal entre seções
- Aderência a padrões de documentação

Visualizações:

- Barras de progresso para completude
- Relatórios de auditoria com detalhamento de não-conformidades
- Dashboards de monitoramento contínuo

4.5 Wireframes Conceituais (Protótipos Iniciais)

Os wireframes propostos visam apresentar uma visualização clara, interativa e hierarquizada das informações extraídas do Plano de Gestão Anual (PGA). Embora ainda em fase conceitual, as telas foram pensadas com foco no uso por gestores acadêmicos, como coordenadores e diretores, destacando pontos críticos e permitindo a comparação entre unidades e categorias.

Tela Principal: Dashboard Geral
- Resumo dos principais indicadores (total de projetos, recursos alocados).
- Gráfico de barras empilhadas com a carga horária por eixo.
- Filtros laterais: unidade, ano, prioridade, tipo de projeto.

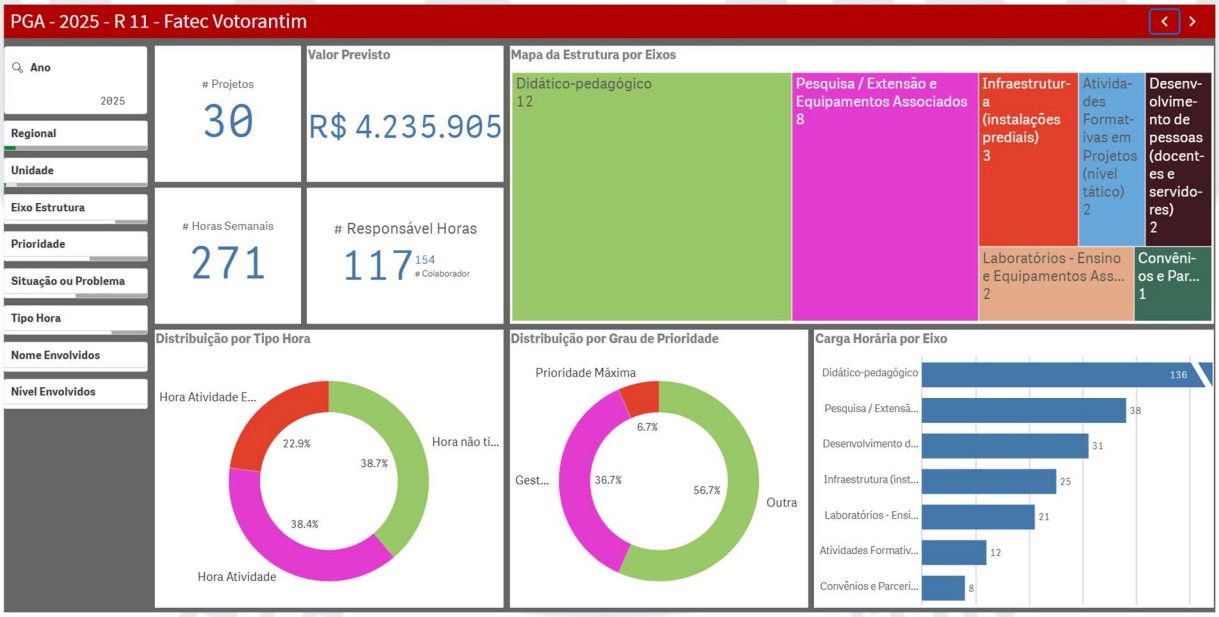


Figura 5- Dashboard Geral

Tela SelfService
- Tabela SelfService BI, onde é possível escolher os campos e medidas.

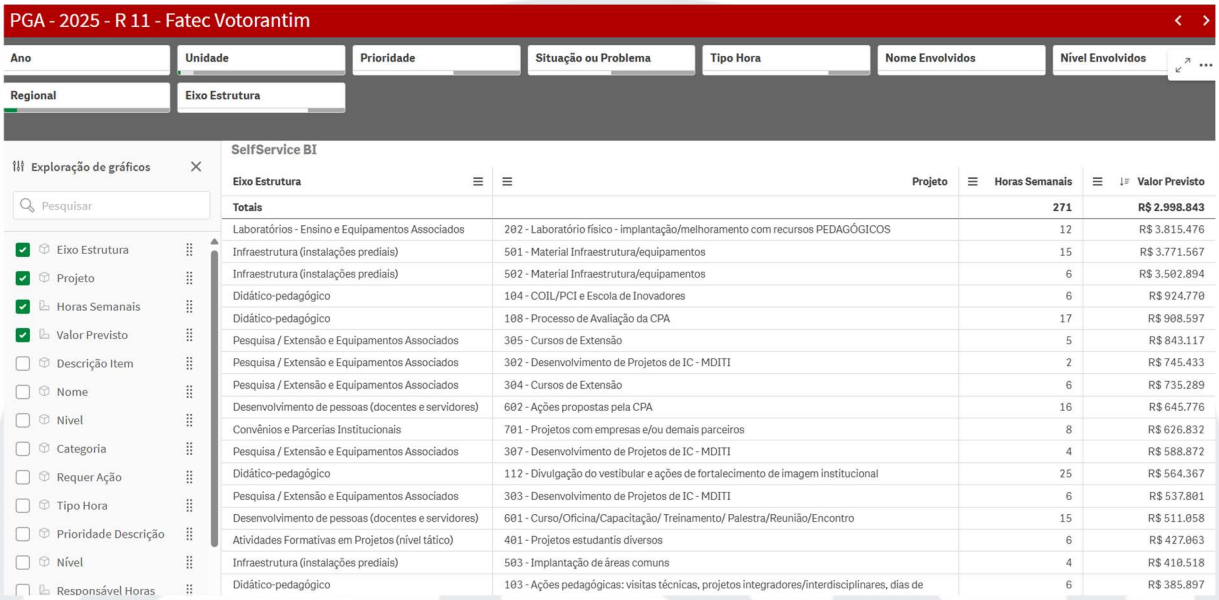


Figura 6 - SelfService BI

Tela Impressão de Projetos
- Tabelas que vislumbram o objeto origem do PDF.

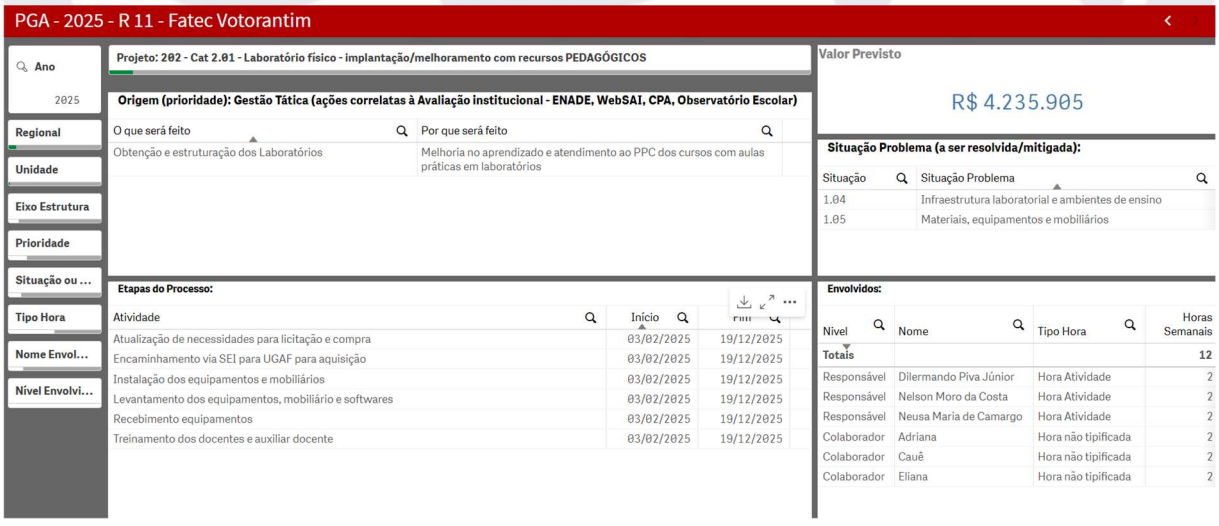


Figura 7 - Detalhamento de Projeto/Ação

4.6 Persona e Fluxo de Uso: Professora Juliana

Persona: Juliana é coordenadora de curso em uma Fatec da Regional 11 e atua diretamente na elaboração e acompanhamento do PGA da unidade.

Necessidades da Juliana:
- Identificar rapidamente projetos pendentes ou fora do prazo.
- Justificar decisões pedagógicas com base em dados históricos.
- Comparar a performance da unidade com outras da regional.

Fluxo de Uso Ideal:
1. Acesso ao dashboard principal com visão geral dos projetos e indicadores da sua unidade.
2. Aplicação de filtros por eixo ou problema identificado (ex: “infraestrutura” ou “problema de segurança”).
3. Análise de alertas de não conformidade em vermelho/amarelo para atuação imediata.
4. Exploração de dashboards comparativos para embasamento em reuniões com a direção ou com o NDE.

4.7 Fundamentação das Análises no Parecer PGA

As análises qualitativas e quantitativas previstas neste projeto foram construídas com base nos conteúdos recorrentes dos pareceres PGA das Fatecs da Regional 11 – Sorocaba. Os documentos analisados incluem registros estruturados e não estruturados sobre:

- Situações-problema relatadas nos relatórios da CPA, CIPA, NDE e Hórus;

- Planejamentos por eixo (Didático, Pesquisa, Infraestrutura etc.);

- Cronogramas e etapas por projeto;

- Alocação de recursos humanos e financeiros.

A transformação dessas informações em indicadores e visualizações interativas tem como objetivo tornar a análise dos PGAs mais objetiva, padronizada e útil para a gestão estratégica.

5. CONSIDERAÇÕES FINAIS

A proposta apresentada neste trabalho representa uma iniciativa concreta e inovadora para transformar a gestão educacional das Fatecs por meio da automatização da análise dos Planos de Gestão Anual (PGA). Ao empregar um pipeline de dados inteiramente desenvolvido em Python, com tecnologias consolidadas e arquitetura Snowflake, o projeto não apenas oferece uma resposta técnica ao desafio de tratar dados não estruturados, mas também promove uma cultura de decisões baseadas em evidências no âmbito institucional.

A aplicação prática do conhecimento adquirido no curso de Ciência de Dados para Negócios reforça o potencial transformador da formação acadêmica, conectando teoria e prática em um problema real e relevante. A ferramenta proposta tem potencial de escalar para todas as unidades do Centro Paula Souza, ampliando a padronização, a transparência e a eficiência dos processos de planejamento estratégico.

Espera-se que, com a continuidade do projeto e seu aprimoramento com base em feedback dos usuários, a solução se consolide como instrumento essencial de apoio à gestão nas instituições de ensino, contribuindo diretamente para a melhoria da qualidade educacional e da eficiência administrativa.

REFERÊNCIAS

KIMBALL, Ralph; ROSS, Margy. The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling. 3. ed. Indianapolis: Wiley, 2013.

KIMBALL, Ralph. The Data Warehouse Toolkit: Practical Techniques for Building Dimensional Data Warehouses. 1. ed. New York: Wiley, 1996.

PYTHON SOFTWARE FOUNDATION. Python Language Reference. Disponível em: https://www.python.org. Acesso em: 10 jun. 2025.

WES McKINNEY. Python for Data Analysis: Data Wrangling with pandas, NumPy, and IPython. 2. ed. Sebastopol: O'Reilly Media, 2018.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.

HUNTER, J. D. Matplotlib: A 2D Graphics Environment. Computing in Science & Engineering, v. 9, n. 3, p. 90-95, 2007.

CENTER PAULA SOUZA. Diretrizes para Elaboração do Plano de Gestão Anual – PGA. São Paulo: CPS, 2023.