CENTRO PAULA SOUZA

FACULDADE DE TECNOLOGIA DE VOTORANTIM

CIÊNCIA DE DADOS PARA NEGÓCIOS

PROJETO INTEGRADOR V

SISTEMA DE RECOMENDAÇÃO POR AFINIDADE

ERIC BERTO

MICHEL CIRILO

VOTORANTIM

JUNHO/2026

RESUMO

O presente trabalho descreve o desenvolvimento e a implementação do Sistema de Recomendação por Afinidade para a empresa Berto Ferramentas, projeto desenvolvido no âmbito do Projeto Integrador V (PI5) do curso de Ciência de Dados para Negócios da Fatec Votorantim. O objetivo central foi criar uma ferramenta de inteligência artificial capaz de sugerir automaticamente itens complementares durante a elaboração de orçamentos, aplicando a técnica de cross-selling para aumentar o ticket médio e reduzir o esquecimento de produtos por parte da equipe de vendas. A solução foi construída sobre um pipeline analítico end-to-end que integra extração de dados do banco HFSQL via ODBC, tratamento e limpeza com Pandas, engenharia de features com Processamento de Linguagem Natural (PLN) — utilizando Regex e Fuzzy Matching (RapidFuzz) para consolidar 5.051 SKUs em 1.938 entidades canônicas — e modelagem preditiva com o algoritmo FP-Growth (MLxtend). O modelo gerou 2.004 regras de associação validadas por métricas de suporte, confiança e sustentação (lift), sendo disponibilizado aos vendedores por meio de uma API REST assíncrona desenvolvida com FastAPI e Uvicorn. Os resultados demonstraram que a aplicação do funil de PLN foi o fator crítico para contornar a esparsidade extrema da base (99,94%), viabilizando a extração de padrões de coocorrência confiáveis e entregando uma ferramenta prática e responsiva para o ambiente de varejo da empresa parceira.

Palavras-chave: Sistema de Recomendação. FP-Growth. Regras de Associação. Processamento de Linguagem Natural. Cross-Selling. FastAPI. Ciência de Dados.

ABSTRACT

This work describes the development and implementation of the Affinity-Based Recommendation System for Berto Ferramentas, a project developed within the scope of the Integrative Project V (PI5) of the Data Science for Business program at Fatec Votorantim. The main objective was to create an artificial intelligence tool capable of automatically suggesting complementary items during the budgeting process, applying cross-selling techniques to increase the average ticket and reduce the sales team's tendency to overlook products. The solution was built on an end-to-end analytical pipeline that integrates data extraction from an HFSQL database via ODBC, data processing and cleaning with Pandas, feature engineering using Natural Language Processing (NLP) — employing Regex and Fuzzy Matching (RapidFuzz) to consolidate 5,051 SKUs into 1,938 canonical entities — and predictive modeling with the FP-Growth algorithm (MLxtend). The model generated 2,004 association rules validated by support, confidence, and lift metrics, and was made available to sales staff through an asynchronous REST API developed with FastAPI and Uvicorn. The results demonstrated that the NLP processing funnel was the critical factor in overcoming the extreme sparsity of the dataset (99.94%), enabling the extraction of reliable co-occurrence patterns and delivering a practical, responsive tool for the retail environment of the partner company.

Keywords: Recommendation System. FP-Growth. Association Rules. Natural Language Processing. Cross-Selling. FastAPI. Data Science.

LISTA DE FIGURAS

Figura 1 – Média de Itens por Cupom.....12
Figura 2 – Itens mais vendidos.....12
Figura 3 – Interface Deploy.....16
Figura 4 – Erro de memória Apriori.....17
Figura 5 – Fim Execução Script.....19
Figura 6 – Cronograma Projeto.....19

LISTA DE TABELAS

Não há tabelas no presente trabalho.

SUMÁRIO

1. INTRODUÇÃO 6

2. APRESENTAÇÃO DA EMPRESA 6

3. DESCRIÇÃO E ANÁLISE DO PROBLEMA 7

3.1 Análise do Cenário 7

3.2 Diagnóstico e Identificação de Problemas 7

4. REFERENCIAL TEÓRICO / FUNDAMENTAÇÃO 7

4.1 Conceitos de Ciência de Dados: 7

4.2 Métodos de Machine Learning (ML) e Processamento de Linguagem Natural (NLP): 8

4.3 Ferramentas e Tecnologias Utilizadas: 9

5. METODOLOGIA 10

5.1 Fonte de Dados 10

5.2 Pré-Processamento e Tratamento 10

5.3 Modelagem Preditiva 11

5.4 Critérios de Avaliação 11

6. ANÁLISE E RESULTADOS 12

6.1 Análise Exploratória de Dados (EDA) 12

6.2 Tabelas e Gráficos Descritivos 12

6.3 Tratamento Textual e Desempenho do Modelo (PLN e FP-Growth) 13

6.4 Discussão dos Resultados 13

7. PLANEJAMENTO DE DEPLOY 14

7.1 Arquitetura da Solução 14

7.2 Pipeline de Dados 14

7.3 Estratégias de Implementação (Deploy) 15

7.4 Versionamento e Documentação 16

7.5 Comparação de modelos 17

8. CRONOGRAMA 18

9. CONCLUSÃO 19

10. REFERÊNCIAS 21

11. ANEXOS 22

11.1 Manual do Usuário 22

11.2 Guia Deploy.....23
11.3 Apresentação 26

1. INTRODUÇÃO

O Projeto Integrador IV (PI5) representa a aplicação prática dos conhecimentos adquiridos ao longo do curso de Ciência de Dados para Negócios. O objetivo é desenvolver soluções baseadas em dados para desafios reais enfrentados por empresas parceiras, consolidando competências técnicas e analíticas. Neste contexto, foi criado o projeto 'Sistema de Recomendação por Afinidade', em parceria com a empresa Berto Ferramentas, com o propósito de apresentar opções de itens a serem incluídos em um orçamento, otimizando a tomada de decisão e promovendo a transformação digital da empresa.

2. APRESENTAÇÃO DA EMPRESA

A Berto Ferramentas é uma loja de médio porte localizada na zona oeste de Sorocaba (SP), na Av. Elias Maluf, 1156. Fundada com o propósito de atender às demandas da comunidade local no segmento de construção e manutenção, a empresa inicialmente atuava como um home center. Atualmente, está em processo de transição estratégica para focar no segmento de ferramentas e tintas, buscando se consolidar como referência regional.

Missão: Facilitar a vida dos clientes oferecendo soluções práticas e de qualidade em ferramentas e tintas, com preços competitivos e atendimento próximo e especializado.

Visão: Ser reconhecida como a principal referência em ferramentas e tintas da região oeste de Sorocaba, destacando-se pela inovação, excelência no atendimento e relacionamento de confiança com clientes e parceiros.

Valores:

- Compromisso com o cliente: oferecer suporte especializado e atendimento de qualidade.
- Transparência: manter relações éticas e de confiança com clientes, fornecedores e colaboradores.
- Qualidade: garantir produtos que atendam padrões de durabilidade e eficiência.
- Inovação: buscar constantemente melhorias em processos e soluções oferecidas.
- Responsabilidade social e ambiental: atuar de forma sustentável e contribuir com a comunidade local.

3. DESCRIÇÃO E ANÁLISE DO PROBLEMA

3.1 Análise do Cenário

O varejo de ferramentas e materiais de construção é altamente competitivo, com margens cada vez mais dependentes da eficiência operacional. Empresas de médio porte enfrentam desafios em digitalização e integração de sistemas. A ausência de relatórios automatizados dificulta o acompanhamento de indicadores de desempenho e a tomada de decisões baseada em dados.

3.2 Diagnóstico e Identificação de Problemas

A empresa percebeu a necessidade de evoluir sua maturidade analítica: passar de um foco apenas no histórico ("olhar retrovisor" do Projeto Faturômetro PI4) para uma inteligência preditiva voltada para o futuro. O principal problema identificado no atendimento diário é que a oferta de itens complementares durante as vendas depende exclusivamente da memória e da experiência do vendedor. Isso tem gerado falhas por esquecimento de produtos e, consequentemente, a perda de boas oportunidades de venda.

Para solucionar esse problema, o projeto PI5 visa desenvolver e implementar um algoritmo de inteligência artificial focado em recomendação preditiva. A ferramenta analisará a base histórica e os padrões de compra para sugerir de forma automática itens complementares (técnica de cross-selling) quando a equipe de vendas estiver criando os orçamentos.

Os objetivos específicos desta implementação incluem:

- Aumentar o ticket médio das compras.
- Reduzir o esquecimento de itens por parte dos vendedores.
- Garantir mais agilidade no atendimento ao cliente.
- Otimizar o giro de estoque da loja.

4. REFERENCIAL TEÓRICO / FUNDAMENTAÇÃO

A seguir, apresentamos a descrição detalhada dos conceitos, métodos e ferramentas tecnológicas que embasam o desenvolvimento do Sistema de Recomendação da Berto Ferramentas.

4.1 Conceitos de Ciência de Dados:

- **Análise de Cesta de Compras (*Market Basket Analysis*):** Trata-se de uma técnica analítica voltada à descoberta de padrões de coocorrência no histórico de transações, permitindo entender quais produtos são frequentemente comprados juntos. Na

perspectiva de **Tan, Steinbach e Kumar (2009)** e de **Aggarwal (2015)**, essa abordagem baseia-se na mineração de dados transacionais para revelar associações e comportamentos ocultos que possuem alto valor comercial.

- **Venda Cruzada (*Cross-Selling*):** É a aplicação negocial da análise preditiva, cujo objetivo é sugerir proativamente itens complementares durante a elaboração de um orçamento, visando o aumento orgânico do ticket médio.
- **Regras de Associação:** Refere-se à extração de padrões lógicos estruturados na forma de "antecedente" e "consequente". Conforme explicitado por **Han, Kamber e Pei (2011)**, a avaliação dessas regras não obedece às métricas de classificação tradicionais, mas sim a indicadores específicos do algoritmo que medem a significância estatística das conexões identificadas:
    - **Suporte (*Support*):** Mede a frequência com que dois ou mais itens aparecem juntos em toda a base de transações históricas.
    - **Confiança (*Confidence*):** Indica a probabilidade de que o produto "B" seja comprado, considerando que o produto "A" já foi incluído na cesta.
    - **Sustentação (*Lift*):** Representa a força da associação, demonstrando o quanto a venda conjunta de ambos os itens supera a probabilidade de serem comprados aleatoriamente de forma isolada.

4.2 Métodos de Machine Learning (ML) e Processamento de Linguagem Natural (NLP):

- **Algoritmo *FP-Growth* (ML):** O modelo escolhido para atuar como motor de regras de associação é o Frequent Pattern Growth (FP-Growth), que substituiu o tradicional algoritmo Apriori. Essa substituição ocorreu pois o FP-Growth processa os dados de forma mais rápida e eficiente utilizando uma estrutura de árvore compacta denominada FP-Tree. Conforme explicam **Han, Kamber e Pei (2011)**, esse método extrai os padrões frequentes em tempo linear e sem a necessidade de gerar exaustivamente dados candidatos a cada iteração, reduzindo o custo computacional.
- **Expressões Regulares / *Regex* (NLP):** Método de Processamento de Linguagem Natural utilizado na engenharia de features para a limpeza e padronização primária das bases. De acordo com **Jurafsky e Martin (2009)**, as expressões regulares são estruturas fundamentais para o casamento e tratamento de padrões de texto. No pipeline

desenvolvido, o Regex é aplicado para extrair o nome "canônico" dos produtos, removendo lixos estruturais, unidades de medida (como KG e ML) e variações irrelevantes, gerando assim um "Produto Mestre" representativo.

- **Correspondência Difusa / *Fuzzy Matching* (NLP):** Abordagem algorítmica utilizada para agrupar e unificar produtos que são idênticos no mundo real, mas que apresentam falhas de digitação ou divergências tipográficas no banco de dados. O modelo ignora a ordem das palavras durante a comparação por meio do uso da métrica token_sort_ratio. Adicionalmente, amparado nos conceitos de processamento de strings e distância de edição discutidos por **Jurafsky e Martin (2009)**, essa técnica permite que o motor de busca na interface do usuário retorne sugestões precisas mesmo quando o operador digita o nome do produto de forma aproximada ou com erros.

4.3 Ferramentas e Tecnologias Utilizadas:

A arquitetura da solução baseia-se em um conjunto de tecnologias modernas, descritas a seguir:

- **Linguagem de Programação:** *Python 3.x* (especificamente versão 3.10) atua como a linguagem base do projeto ponta a ponta.
- **Manipulação e Limpeza de Dados:** A biblioteca *Pandas* é o alicerce para a extração, tratamento e agrupamento semântico (*ETL*) dos dados brutos, explorando métodos nativos otimizados (como o *map()*).
- **Banco de Dados:** O sistema original da empresa consome dados de um banco relacional *HFSQL*, acessado pela aplicação através de uma conexão ODBC utilizando o driver *pypyodbc*. O fluxo extrai principalmente a matriz de coocorrência da tabela TAB_VENDA_ITEM.
- **Frameworks Analíticos:** *RapidFuzz* foi a ferramenta selecionada para a execução rápida e eficiente das operações de *Fuzzy Match*. Adicionalmente, o código utiliza a biblioteca *MLxtend* para invocar a execução do FP-Growth e extrair as regras de associação matemáticas.
- **Infraestrutura:** A sustentação tecnológica da solução baseia-se no uso do servidor assíncrono Uvicorn, configurado para disponibilizar o serviço no ambiente local através da porta de rede 8000.

- **Interface (API):** O acesso dos usuários (vendedores) ao motor de recomendação ocorre por meio de uma API REST assíncrona desenvolvida sob o framework FastAPI. Esta camada é responsável pelo encapsulamento lógico do modelo preditivo em um microsserviço.

5. METODOLOGIA

A arquitetura do Sistema de Recomendação Inteligente (v3.0) da Berto Ferramentas foi estruturada em um pipeline de dados analítico de ponta a ponta (end-to-end), organizado em cinco etapas fundamentais: Extração, Pré-processamento (Saneamento e EDA), Engenharia de Features (Produto Mestre), Modelagem (FP-Growth) e Disponibilização (API).

A seguir, são detalhados os componentes solicitados:

5.1 Fonte de Dados

A ingestão de dados ocorre diretamente do banco de dados relacional HFSQL utilizado no sistema de PDV da loja.

Tabelas consumidas: O sistema extrai informações essenciais das tabelas TAB_VENDA_ITEM (matriz principal de coocorrência), TAB_VENDA e TAB_PRODUTO.

Conexão: A extração é viabilizada na linguagem Python através do driver ODBC pypyodbc, utilizando a instrução CAST para converter os tipos de dados e garantir a consistência das colunas (como ven_id, pro_id e descricao) durante o processamento analítico.

5.2 Pré-Processamento e Tratamento

O fluxo de limpeza e preparação dos dados foca em garantir a integridade da base para a geração de regras consistentes:

Saneamento Básico: Remoção de colunas 100% nulas, variáveis constantes (sem variância) e de registros de vendas inválidas, canceladas ou com valores zerados.

Filtragem de Cestas: Vendas contendo apenas um item (single-item) são removidas da base de treino, pois algoritmos de regras de associação necessitam de transações com múltiplos itens (multi-item) para encontrar padrões lógicos de coocorrência.

Engenharia de Features (Produto Mestre): Para corrigir falhas de digitação e variações de nomenclatura no banco de dados, o pipeline agrupa produtos similares utilizando métodos de Processamento de Linguagem Natural (NLP):

- **Regex**: Limpa pontuações e remove unidades de medida variáveis (como KG, ML, UN, GR).
- **Fuzzy Matching**: Aplica a biblioteca RapidFuzz (usando a métrica token_sort_ratio para ignorar a ordem das palavras) visando agrupar variações tipográficas em uma única entidade canônica representativa, chamada de "Produto Mestre".

5.3 Modelagem Preditiva

A etapa de modelagem visa identificar os padrões de compra na cesta dos clientes:

Algoritmo FP-Growth: O motor de recomendação utiliza o algoritmo Frequent Pattern Growth (via biblioteca mlxtend), escolhido para substituir o Apriori.

Vantagem do Modelo: O modelo mapeia a base de transações usando uma estrutura de árvore compacta (FP-tree), o que permite encontrar padrões frequentes em tempo linear O(n) e sem a necessidade de gerar dados candidatos de maneira exaustiva, tornando o processamento mais eficiente computacionalmente.

5.4 Critérios de Avaliação

Como se trata de um modelo baseado em regras de associação e não em classificação tradicional, os critérios de avaliação (métricas de desempenho) são específicos do algoritmo:

Suporte (Support): Avalia a frequência percentual com que os itens (ou o conjunto de itens) aparecem juntos no histórico total de transações.

Confiança (Confidence): Mensura a probabilidade condicional de o item "B" ser comprado, dado que o item "A" já foi adicionado ao carrinho.

Sustentação (Lift): É a métrica de força da regra. Ela indica o quanto a probabilidade de comprar os itens juntos supera a probabilidade de comprá-los de forma aleatória e independente.

Esse pipeline é finalmente encapsulado em um microsserviço (API REST usando FastAPI e Uvicorn), que permite ao sistema de vendas buscar os produtos mais recomendados.

6. ANÁLISE E RESULTADOS

6.1 Análise Exploratória de Dados (EDA)

A etapa de análise exploratória avaliou o histórico de vendas para compreender os padrões de faturamento e de formação de cestas dos clientes. A base de dados original continha 20.132 registros, totalizando um faturamento de R$ 936.107,60, com Ticket Médio avaliado em R$ 46,50 e um valor máximo de compra de R$ 2.257,70. Durante o saneamento, foram excluídas 224 transações (1,11%) que apresentavam valores iguais ou inferiores a zero, resultando em 19.908 registros de vendas válidos para exploração.

6.2 Tabelas e Gráficos Descritivos

As representações visuais construídas na EDA trouxeram insumos importantes sobre o comportamento de compra:

Distribuição das Cestas: Os gráficos indicaram que as compras na loja possuem uma média inicial de itens por cupom em 2,06 produtos.

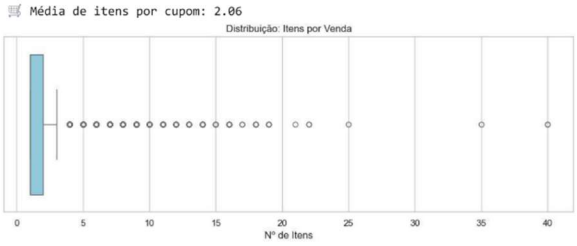


Figura 1- Média de Itens por Cupom

Top Produtos Mais Vendidos: O ranqueamento gráfico destacou produtos de alta saída, sendo os principais: "Aguarras 900ml Itaqua", "Massa Corrida Barrica 20kg Parana", "Bucha 08 Anel" e "Acri Branco Eco 16L Parana".

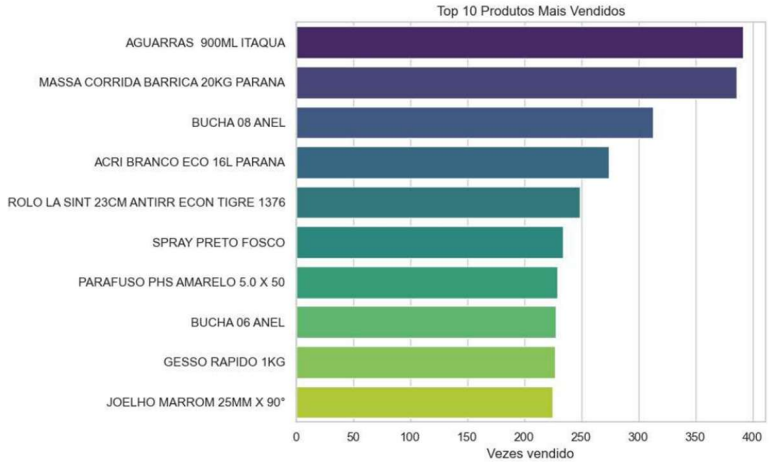


Figura 2 - Itens mais vendidos

Esparsidade e Coocorrência: A análise da matriz de coocorrência (produtos comprados juntos) apontou para uma esparsidade de 99,9466%, indicando que a grande maioria das combinações possíveis de itens nunca ocorreu simultaneamente no histórico.

6.3 Tratamento Textual e Desempenho do Modelo (PLN e FP-Growth)

Para contornar a alta esparsidade estrutural e melhorar a performance analítica, foi implementado o funil de Processamento de Linguagem Natural (PLN) antes do treinamento:

Redução de Dimensão (Regex + Fuzzy Match): Dos 5.051 SKUs originais extraídos do banco, a aplicação de Regex reduziu a base para 3.123 itens. Em seguida, o Fuzzy Match realizou 1.185 fusões de nomenclaturas com variações tipográficas, consolidando o catálogo em apenas 1.938 "Entidades Mestres". Isso resultou em uma redução de dimensão de 61,63% na base de variáveis.

Métricas de Treinamento: O algoritmo FP-Growth utilizou apenas cestas de vendas contendo múltiplos itens totalizando 8.625 transações utilizadas no modelo.

Desempenho da Extração: Configurado com um limiar de suporte muito sensível de 0,001 (0,1%), o modelo processou a matriz e identificou 1.165 conjuntos de itens frequentes. A partir desse conjunto, o FP-Growth entregou 2.004 regras de associação finais de alta confiabilidade.

6.4 Discussão dos Resultados

Os resultados demonstram que a aplicação do funil de PLN foi o fator crítico de sucesso do projeto analítico. Sem a redução de 61,63% na multiplicidade dos SKUs promovida pelo Fuzzy Match, a esparsidade extrema da base (99,94%) faria com que a frequência de vendas ficasse diluída entre produtos idênticos grafados de formas diferentes. Isso impediria que o FP-Growth atingisse o suporte mínimo necessário para encontrar associações válidas.

Ao treinar o modelo em cima das 8.625 vendas com mais de um produto e criar 2.004 regras validadas por métricas de Sustentação (Lift) e Confiança, o projeto entrega uma base de inteligência robusta. Esse desempenho garante que a interface do usuário possa sugerir compras complementares com base em correlações reais, sustentando diretamente o objetivo de aumentar o ticket médio da Berto Ferramentas e diminuir o esquecimento de itens pela equipe de vendas.

7. PLANEJAMENTO DE DEPLOY

O guia detalhado de deploy e arquitetura da solução do Sistema de Recomendação Inteligente da Berto Ferramentas, estruturado conforme as informações documentadas do projeto.

7.1 Arquitetura da Solução

A arquitetura do sistema foi desenhada sob um modelo end-to-end (ponta a ponta), operando de forma assíncrona. O fluxo arquitetural segue o seguinte caminho: Banco de Dados (HFSQL) → Extração & Tratamento (Pandas) → Agrupamento Semântico (Regex + Fuzzy Match) → Motor de Regras (FP-Growth) → API REST (FastAPI) / Interface do Vendedor.

O modelo preditivo não roda de forma passiva; ele é encapsulado em um microsserviço assíncrono, disponibilizado aos vendedores por meio de uma API web de execução local. Conforme aponta Newman (2015), a arquitetura baseada em microsserviços promove o desacoplamento (loose coupling) e a alta coesão entre componentes. Essa abordagem isola o motor de recomendação de forma autônoma, garantindo que falhas ou atualizações no modelo não impactem a estabilidade das demais rotinas operacionais e comerciais já existentes no sistema de ponto de venda (PDV) da loja.

7.2 Pipeline de Dados

O pipeline de dados prepara as informações transacionais brutas para que o modelo consiga extrair padrões confiáveis. Na visão de **Kleppmann (2017)**, um pipeline de dados caracteriza-se como um fluxo automatizado de processamento sequencial, sendo um elemento crítico em sistemas intensivos em dados para assegurar a consistência, integridade e transformação progressiva de registros legados. No cenário deste projeto, as fases do funil analítico são divididas:

Ingestão de Dados: A aplicação conecta-se ao banco de dados HFSQL utilizando a biblioteca pypyodbc. A tabela de origem principal é a TAB_VENDA_ITEM, e a extração emprega a função CAST do SQL para forçar a conversão dos campos (ven_id, pro_id, descricao) para formato texto VARCHAR, evitando erros de tipagem ao transferir as linhas para o Python. O bloco de conexão utiliza rotinas try/finally para garantir que o banco seja fechado corretamente e não crie gargalos.

Tratamento e Limpeza (ETL): Exclusão de ruídos, colunas nulas, constantes sem variação, e o descarte rigoroso de transações com valores zerados ou canceladas.

Engenharia do "Produto Mestre" (PLN): Fase crucial para reduzir a dimensionalidade. Primeiro, aplica-se Regex para remover marcações irrelevantes e unidades de medida (ML, KG, GR, etc.). Em seguida, o algoritmo RapidFuzz atua como correspondente difuso (usando a métrica token_sort_ratio para ignorar a ordem das palavras). Ele funde produtos idênticos que foram cadastrados com divergências de digitação, escolhendo o termo mais comum no banco como o nome oficial.

Modelagem FP-Growth: Com as descrições padronizadas, a base passa por uma matriz de coocorrência booleana (One-Hot). O algoritmo FP-Growth processa as transações de múltiplos itens gerando, de forma super-rápida, um catálogo de regras de associação baseadas em antecedentes e consequentes validados por suporte e confiança.

7.3 Estratégias de Implementação (Deploy)

Para a implementação prática nas frentes de atendimento da loja, a disponibilização do motor de recomendação ocorre via uma API *RESTful* desenvolvida sob o framework *FastAPI* . De acordo com a teoria fundamental de **Fielding (2000)**, o padrão arquitetural *REST (Representational State Transfer)* estabelece um conjunto de restrições de interface uniforme que otimizam a escalabilidade, a portabilidade e a independência de plataformas através da transferência de estados representacionais via métodos HTTP padronizados, as especificações detalhadas de conectividade e parâmetros de rede estão documentadas no Guia de Deploy (Item 11.2)

Serviço de API: A disponibilização do motor de recomendação ocorre via uma API RESTful desenvolvida com o framework FastAPI.

Servidor: A aplicação de back-end roda por meio do servidor assíncrono Uvicorn, hospedado no ambiente local.

Interface Tolerante a Erros: O endpoint da API /api/busca possui funcionalidade de Fuzzy Match nativa. Isso significa que, durante o atendimento em loja, o vendedor não é obrigado a digitar o nome exato do produto; o sistema compreende abreviações ou erros de digitação e retorna os produtos mais próximos, e devolve os itens de venda cruzada ("*cross-selling*") em tempo real para a tela.

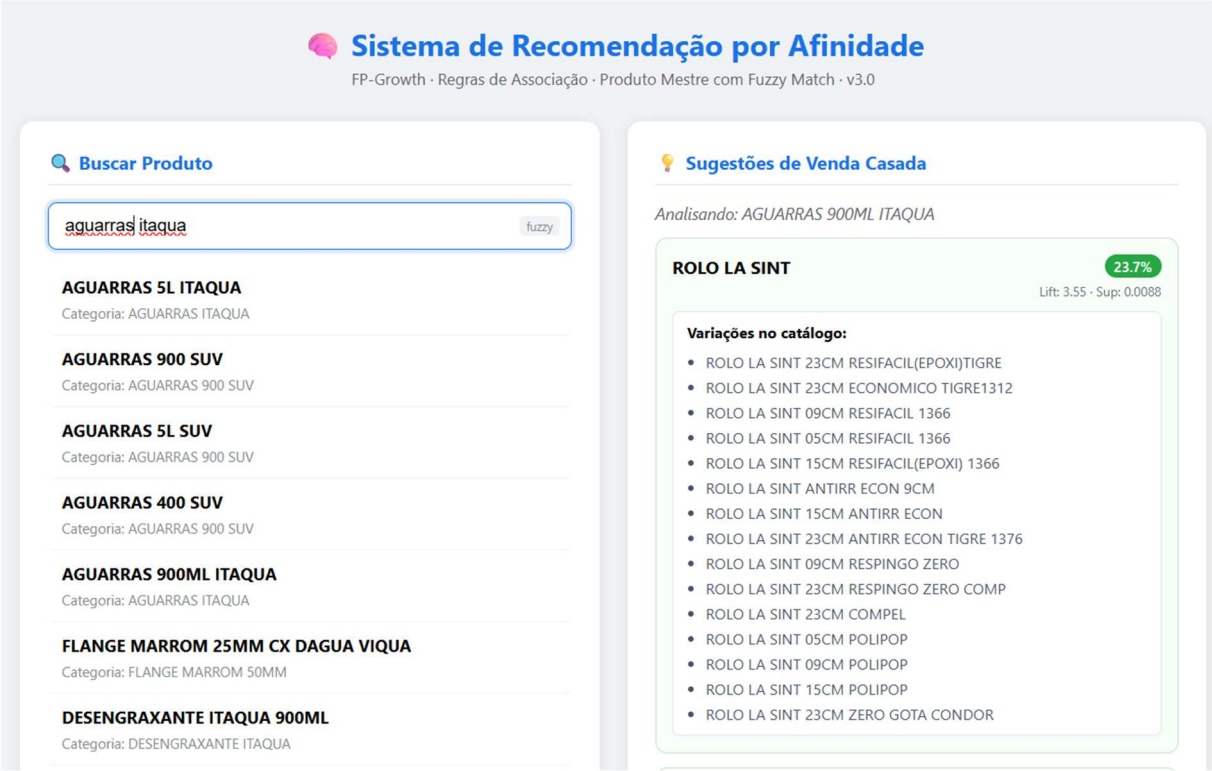


Figura 3 - Interface Deploy

7.4 Versionamento e Documentação

Controle de Versão: A implementação atual refere-se à versão v3.0. Nesta versão, além do FP-Growth que já havia substituído o algoritmo Apriori, foram integradas a biblioteca RapidFuzz, uma célula de calibração para encontrar a sensibilidade ideal de agrupamento (threshold de diagnóstico) e a busca flexível na própria interface da API.

Armazenamento de Código: O repositório oficial da solução abriga os arquivos de código-fonte, incluindo scripts de integração e o notebook principal (ex: RecVendasv3.ipynb).

Gestão de Conhecimento: A documentação executiva e detalhada (que engloba páginas de Análise EDA, PLN, manuais técnicos e arquitetura FastAPI) está integralmente centralizada e controlada no portal corporativo do Confluence. Testes técnicos confirmaram a consistência dos indicadores e o funcionamento dos filtros. A validação pela empresa parceira demonstrou satisfação com a clareza das informações, sendo sugerida apenas a integração direta com o banco de dados em tempo real.

7.5 Comparação de modelos

O Apriori e o FP-Growth são apenas "caminhos diferentes para chegar ao mesmo destino". A única diferença entre eles está na performance computacional (memória e tempo de processamento).

Apriori: Funciona como um detetive antiquado. Ele gera combinações possíveis e faz uma varredura (scan) completa na sua base de dados para cada nova combinação. É lento e consome muita memória em bases grandes.

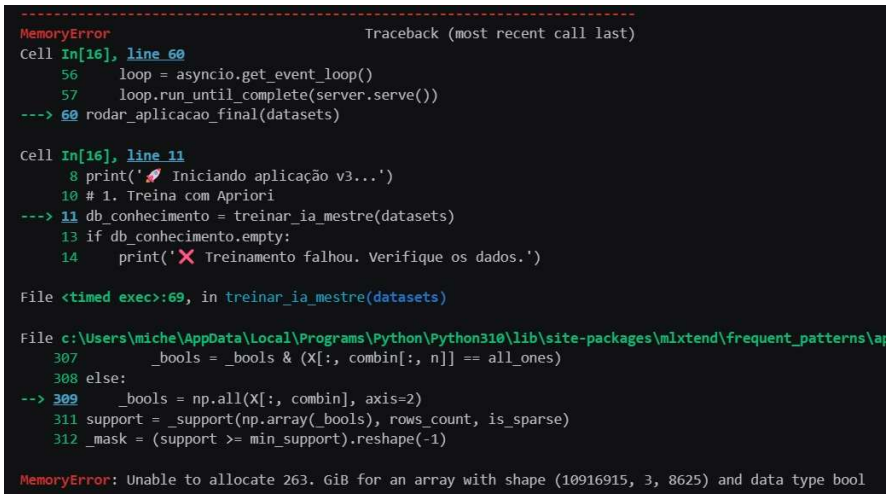


Figura 4 - Erro de memória Apriori

FP-Growth: É mais moderno e eficiente. Ele varre a base de dados apenas duas vezes para construir uma estrutura compacta na memória chamada FP-Tree (Árvore de Padrões Frequentes), extraindo as regras diretamente dessa árvore de forma muito mais rápida.

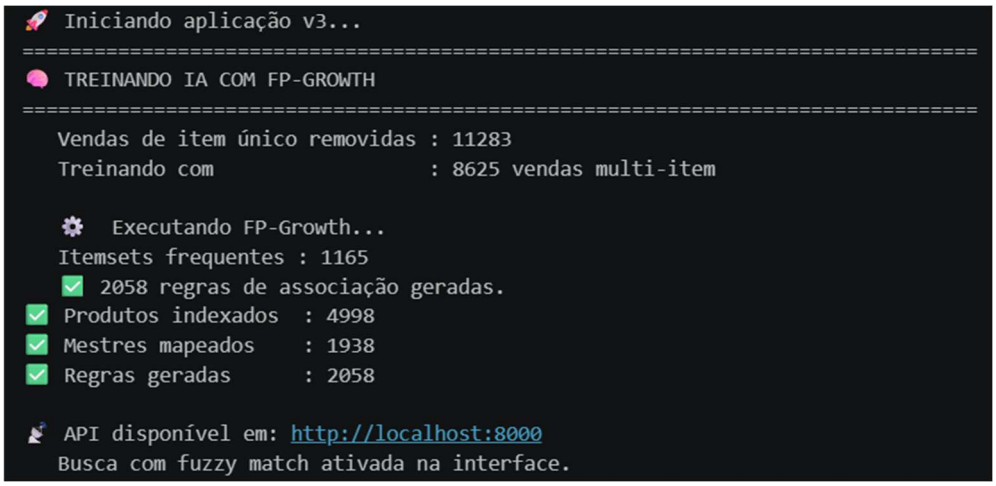


Figura 5 - Fim Execução Script

8. CRONOGRAMA

O planejamento de atividades apresentado no cronograma foi estruturado de forma sequencial e organizada, visando garantir o desenvolvimento eficiente do projeto ao longo dos meses de março, abril e maio. Inicialmente, foi realizada a etapa de Kick Off, responsável pela abertura oficial do projeto, alinhamento das expectativas, definição dos objetivos e distribuição das responsabilidades entre os integrantes da equipe.

Na sequência, ocorreu a fase de gestão do projeto, desenvolvida continuamente durante praticamente todo o período de execução. Essa etapa envolveu o acompanhamento das atividades, organização das sprints, realização de reuniões diárias (daily meetings) e monitoramento do andamento das entregas, garantindo maior controle e alinhamento entre os participantes.

Posteriormente, foi executada a etapa de ETL (Extract, Transform and Load), destinada à extração, tratamento e organização dos dados necessários para o desenvolvimento da solução. Após a preparação dos dados, iniciou-se a fase de modelagem de Machine Learning, na qual foram realizados os treinamentos, testes e ajustes do modelo preditivo utilizado no projeto.

Com a finalização do modelo, foi desenvolvida a documentação do projeto, reunindo informações técnicas, metodologias utilizadas, processos de desenvolvimento e resultados obtidos. Paralelamente, também foi realizada a etapa de deploy, responsável pela implementação e disponibilização da solução desenvolvida.

Por fim, nas últimas semanas do cronograma, ocorreram as atividades de preparação da apresentação final e entrega definitiva do projeto, consolidando todos os resultados produzidos durante o período de desenvolvimento. O planejamento estruturado em etapas permitiu maior organização, acompanhamento contínuo e melhor distribuição das atividades ao longo do projeto.

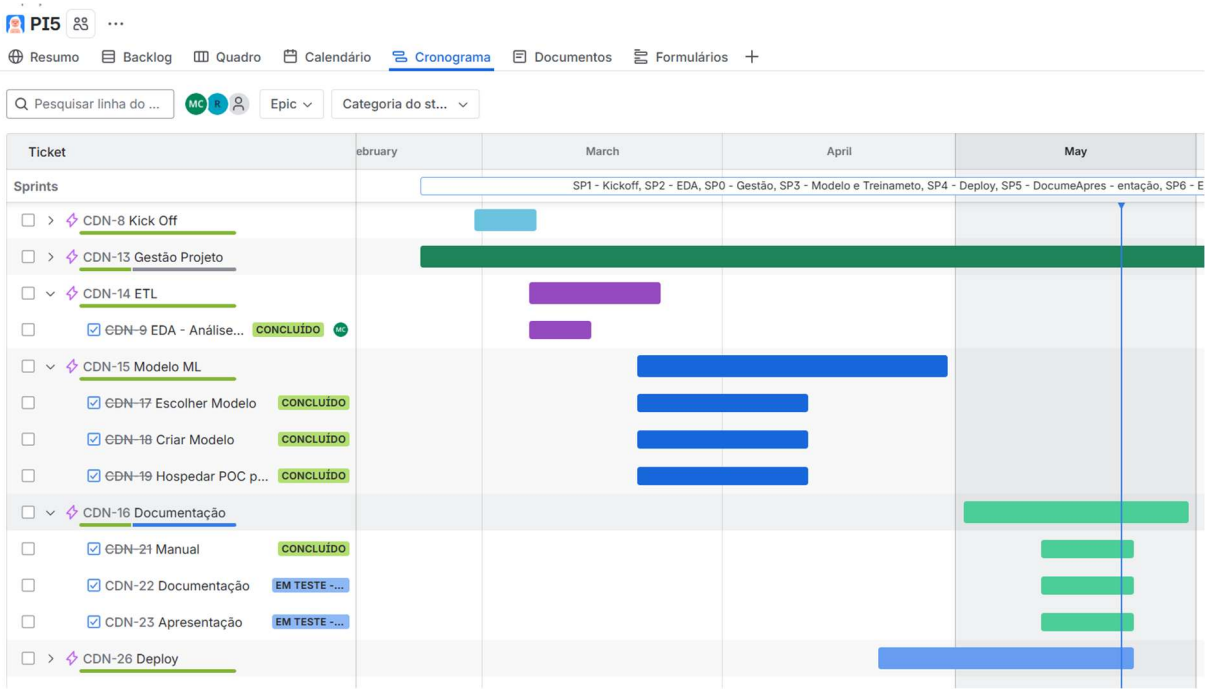


Figura 6 - Cronograma Projeto

9. CONCLUSÃO

O projeto cumpriu seu objetivo central de projetar e implementar um algoritmo de inteligência artificial focado na sugestão automática de itens complementares durante a elaboração de orçamentos. Essa iniciativa marcou a evolução da maturidade analítica da Berto Ferramentas, permitindo que a empresa transitasse de uma visão gerencial retroativa (consolidada no Projeto Faturômetro) para uma inteligência de dados preditiva e orientada ao futuro.

Tecnicamente, a estratégia de desenvolvimento adotada foi o diferencial para o sucesso da solução. A escolha do algoritmo FP-Growth associada ao funil de Processamento de Linguagem Natural (PLN) com Regex e Fuzzy Match mitigou as barreiras da esparsidade extrema dos dados e da inconsistência nas digitações de produtos. Ao agrupar mais de 5.000 nomenclaturas em cerca de 1.938 entidades canônicas ("Produtos Mestres"), o sistema não só extraiu as regras de coocorrência de forma muito mais rápida, como garantiu regras de alta confiabilidade. O encapsulamento do modelo em um microsserviço assíncrono via API entregou uma ferramenta de interface moderna, responsiva e que tolera aproximações de texto na rotina do usuário.

Com a solução entrando em operação, projeta-se que a Berto Ferramentas observe melhorias significativas.

Aumento do Ticket Médio: direcionado pelo estímulo orgânico das compras complementares sugeridas pelo motor de regras;

Eliminação de Oportunidades Perdidas: ao não depender exclusivamente da memória humana, reduz-se drasticamente o esquecimento de itens acessórios por parte dos vendedores;

Eficiência no Atendimento: agilização do processo de orçamento, o que resulta em um serviço de maior excelência para o consumidor da região;

Gestão de Inventário; Maior giro de estoque aliado a um banco de dados agora padronizado, limpo e sem redundâncias de SKUs.

Próximos Passos

Avançando para a implementação em ambiente real, as próximas etapas priorizam a adoção e o engajamento da equipe. Na fase de Testes Piloto e Homologação, deve-se testar de forma prática a interface do sistema, avaliando a precisão das sugestões durante os atendimentos comerciais em tempo real. Posteriormente, a etapa de Calibração do Modelo será dedicada à realização de ajustes finos nas métricas de sensibilidade (threshold) com base no feedback inicial dos operadores, visando mitigar o risco de recomendações irrelevantes conhecidas como falsos positivos.

10. REFERÊNCIAS

AGGARWAL, Charu C. **Data mining**: the textbook. Cham: Springer, 2015. 748 p.

BERTO FERRAMENTAS. **Documentos internos fornecidos pela empresa**, 2026.

CENTRO PAULA SOUZA. **Manual do Projeto Integrador V**, 2026.

FASTAPI. **FastAPI documentation**. 2026. Disponível em: https://fastapi.tiangolo.com/. Acesso em: 23 maio 2026.

FIELDING, Roy Thomas. **Architectural styles and the design of network-based software** architectures. 2000. Tese (Doutorado em Ciência da Computação) – University of California, Irvine, Irvine, 2000.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. **Data mining**: concepts and techniques. 3. ed. Waltham: Morgan Kaufmann, 2012. 744 p.

JURAFSKY, Daniel; MARTIN, James H. **Speech and language processing**: an introduction to natural language processing, computational linguistics, and speech recognition. 2. ed. Upper Saddle River: Pearson Prentice Hall, 2009. 1024 p.

KLEPPMANN, Martin. **Designing data-intensive applications**: the big ideas behind reliable, scalable, and maintainable systems. Sebastopol: O'Reilly Media, 2017.

MLXTEND. **Mlxtend**: providing machine learning and data science tools for Python's everyday data science tasks. 2026. Disponível em: https://rasbt.github.io/mlxtend/. Acesso em: 23 maio 2026.

NEWMAN, Sam. **Building microservices**: designing fine-grained systems. Sebastopol: O'Reilly Media, 2015.

PANDAS. **pandas documentation**. 2026. Disponível em: https://pandas.pydata.org/docs/. Acesso em: 23 maio 2026.

RAPIDFUZZ. **RapidFuzz documentation**. 2026. Disponível em: https://maxbachmann.github.io/RapidFuzz/. Acesso em: 23 maio 2026.

SCRUM ALLIANCE. **O Guia Scrum**. 2025. Disponível em: https://www.scrumalliance.org/learn-about-scrum/the-scrum-guide. Acesso em: 12 out. 2025.

TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. **Introduction to data mining**. Boston: Pearson Addison Wesley, 2006. 769 p.

11. ANEXOS

11.1 Manual do Usuário

Fatec Votorantim

CPS Centro Paula Souza

CENTRO PAULA SOUZA

FACULDADE DE TECNOLOGIA DE VOTORANTIM

CIÊNCIA DE DADOS PARA NEGÓCIOS

PROJETO INTEGRADOR V

SISTEMA DE RECOMENDAÇÃO POR AFINIDADE

Manual do Usuário

ERIC BERTO

MICHEL CIRILO

VOTORANTIM

JUNHO/2026

SUMÁRIO

1. OBJETIVO 3
2. COMO ACESSAR 3
3. CONHECENDO A INTERFACE 3
4. COMO BUSCAR E FILTRAR PRODUTOS 4
5. COMO GERAR RECOMENDAÇÕES PARA O CLIENTE 5

1. Objetivo

Este manual detalha o passo a passo para que os vendedores e operadores da Berto Ferramentas possam acessar a interface do sistema, realizar buscas tolerantes a erros ortográficos e gerar recomendações de vendas cruzadas (*cross-selling*).

2. Como Acessar

O sistema possui uma interface interativa web gerada automaticamente. Para acessá-la, certifique-se de que o servidor local esteja rodando (conforme o Guia de Deploy) e siga os passos:

1. Abra o navegador de internet de sua preferência (Google Chrome, Edge, Firefox, etc.).
2. Na barra de endereços, digite o seguinte endereço: **http://localhost:8000/docs**
3. Pressione **Enter**. A tela principal da interface da API (Swagger UI) será carregada, exibindo as opções de navegação.
4.

3. Conhecendo a Interface

A tela do sistema é dividida em duas áreas principais para agilizar o atendimento:

- **Área de Busca (Principal):** Onde você digita o nome do produto que o cliente está procurando.
- **Painel Lateral (Recomendações):** A área da tela que se atualiza automaticamente para mostrar os produtos sugeridos com base no que foi selecionado.

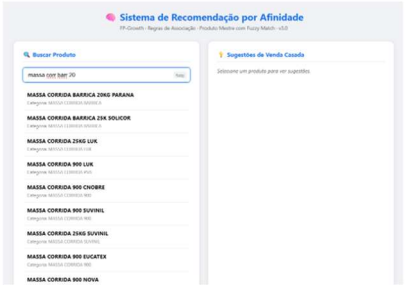


3

4. Como Buscar e Filtrar Produtos

O sistema possui uma busca inteligente tolerante a erros ortográficos. Você não precisa digitar o nome exato ou se preocupar com pequenos erros de digitação (ex: buscar por "parafso" em vez de "parafuso").

- Localize a barra de pesquisa na tela principal do sistema.
- Comece a digitar o nome da ferramenta ou produto que o cliente deseja.
- Conforme você digita, o sistema exibirá uma lista de opções (Produtos Mestres) que mais se assemelham ao texto inserido

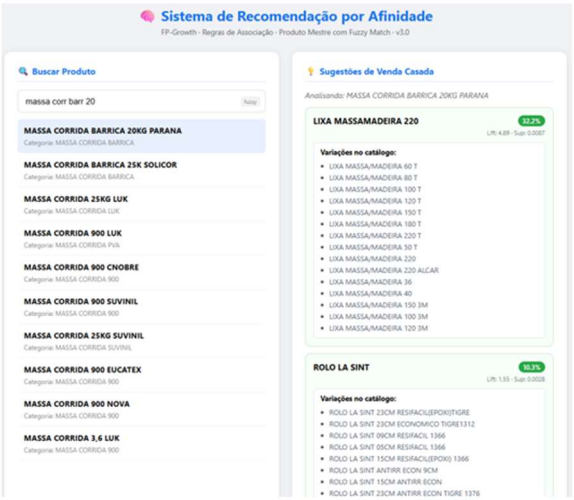


4

5. Como Gerar Recomendações para o Cliente

O processo de recomendação é automático e não exige cliques em botões de confirmação.

1. Com a lista de resultados visível na tela de busca, utilize o mouse para clicar e selecionar o item exato que o cliente está comprando.
2. Imediatamente após a sua seleção com o mouse, o painel lateral será atualizado de forma automática.
3. Observe o painel lateral: ele agora exibirá uma lista de produtos complementares sugeridos (ex: se você selecionou "Tinta", o painel lateral pode sugerir "Rolo de Pintura" ou "Lixa").
4. Ofereça esses itens sugeridos ao cliente para complementar o orçamento e aumentar o ticket médio da venda.



11.2 Guia Deploy



Fatec Votorantim

CPS Centro Paula Souza

CENTRO PAULA SOUZA

FACULDADE DE TECNOLOGIA DE VOTORANTIM

CIÊNCIA DE DADOS PARA NEGÓCIOS

PROJETO INTEGRADOR V

SISTEMA DE RECOMENDAÇÃO POR AFINIDADE

Deploy Guide

ERIC BERTO

MICHEL CIRILO

VOTORANTIM

JUNHO/2026

SUMÁRIO

1. OBJETIVO 3
2. ESCOPO 3
3. DEFINIÇÕES E SIGLAS 3
4. VISÃO GERAL DA APLICAÇÃO 4
5. ARQUITETURA E SOLUÇÃO 4
6. CONFIGURAÇÃO DO AMBIENTE 5
6.1 Instalação 5
6.2 Criação do Ambiente Virtual 5
6.3 Instalação de Dependências 5
7. EXECUÇÃO E DEPLOY 6
7.1 Subir o Servidor 6
7.2 Configurações do Servidor 6
8. MONITORAMENTO 7

1. OBJETIVO

Descrever o processo detalhado de implantação (deploy) do modelo preditivo Sistema de Recomendação por Afinidade (Versão 3.0) desenvolvido para a Berto Ferramentas. Este guia estabelece os requisitos técnicos, arquiteturais e de monitoramento para garantir o funcionamento contínuo do motor de cross-selling no ambiente de produção da loja.

2. ESCOPO

Este documento cobre rigorosamente as seguintes etapas do ciclo de vida da aplicação:

- Provisionamento e configuração do ambiente virtual (Python 3.10).
- Conexão e ingestão de dados legados do sistema HFSQL.
- Pré-processamento, engenharia de features (Regex + Fuzzy Matching).
- Execução local e em produção dos serviços de API (FastAPI/Uvicorn).
- Governança, segurança, testes de calibração e estratégias de re-treinamento do modelo FP-Growth.

3. DEFINIÇÕES E SIGLAS

TERMO	DEFINIÇÃO
ML	Machine Learning (Aprendizado de Máquina)
PLN	Processamento de Linguagem Natural
FP-Growth	Frequent Pattern Growth: Algoritmo avançado para mineração de regras de associação e coocorrência de produtos.
Fuzzy Matching	Correspondência difusa de strings (via biblioteca RapidFuzz) para agrupar produtos com variações tipográficas.
SKU	Stock Keeping Unit: Unidade de Manutenção de Estoque.
HFSQL	Banco de dados relacional proprietário utilizado pela Berto Ferramentas, acessado via driver ODBC.
API	Interface de Programação de Aplicações
Endpoint	Ponto final de conexão para consumo de dados

4. VISÃO GERAL DA APLICAÇÃO

Descrição do Modelo: O sistema analisa a base histórica de mais de 40 mil itens transacionados da Berto Ferramentas para gerar inteligência preditiva. Ele substitui a dependência da memória humana durante o atendimento ao sugerir ativamente itens complementares, otimizando oportunidades de venda.

Tipo de Modelo: Sistema de Recomendação baseado em Regras de Associação (Aprendizado Não Supervisionado).

Fluxo da Solução (Pipeline):

1. Extração: Ingestão via ODBC das tabelas TAB_VENDA_ITEM, TAB_VENDA, e TAB_PRODUTO.
2. Saneamento e EDA: Remoção de nulos, variáveis constantes e vendas zeradas (criação de matriz esparsa).
3. Engenharia de Produto Mestre: Redução de dimensionalidade aplicando Regex (limpeza estrutural) e RapidFuzz (threshold=82 com scorer token_sort_ratio). Redução de 5.051 SKUs para 1.938 Entidades Mestres.
4. Predição: Mineração de regras multicritério com FP-Growth avaliando Suporte, Confiança e Sustentação (Lift).
5. Consumo: Exposição das regras em uma interface front-end que consulta a API FastAPI, seguir, apresentamos a descrição detalhada dos conceitos, métodos e ferramentas tecnológicas que embasam o desenvolvimento do Sistema de Recomendação da Berto Ferramentas.

5. ARQUITETURA E SOLUÇÃO

A O ecossistema é baseado em microsserviços rodando localmente na rede da loja:

- Camada de Dados (Data Layer): Banco HFSQL (A37278473). Conexão gerida via pypyodbc.

- Camada de Lógica/Modelo (Processing Layer): Pipeline Python que roda periodicamente para atualizar o dicionário de regras (Catalogo Busca, Mestres Mapeados, Regras Geradas).
- Camada de Serviço (API Layer): API RESTful assíncrona construída com FastAPI e servida via Uvicorn.
- Camada de Interface (Client/Frontend): Sistema de caixa/vendas que faz requisições HTTP POST/GET.

6. CONFIGURAÇÃO DO AMBIENTE

6.1 Instalação

Instalação do Python 3.10 e driver ODBC para HFSQL configurado no DSN do Windows/Linux.

6.2 Criação do Ambiente Virtual

git clone https://github.com/PI4-Grupo5/ProjetoBertoFerramentas/tree/main/PI5/Entregaveis

cd recomendacao-afinidade-v3

python -m venv venv

Ativação no Windows:

venv\Scripts\activate

6.3 Instalação de Dependências

Um arquivo requirements.txt deve conter as versões validadas no desenvolvimento. Ainstalação básica requer:

pip install rapidfuzz mlxtend fastapi uvicorn nest_asyncio pypyodbc pandas numpy matplotlib seaborn

7. EXECUÇÃO E DEPLOY

O "deploy" desta versão ocorre mediante a execução direta do script (ex: RecVendasv3.ipynb ou a sua versão exportada em .py). Não há utilização de contentores (como Docker) ou serviços na nuvem. O próprio script cuida da inicialização do servidor web após finalizar o treino do modelo.

7.1 Subir o Servidor

No final da execução da pipeline de dados, o script configura e inicia o Uvicorn nativamente:

```
import uvicorn
import nest_asyncio
import asyncio

# Aplica correção para loops assíncronos em notebooks
nest_asyncio.apply()

# Configuração do servidor a apontar para a app FastAPI
config = uvicorn.Config(app, host='0.0.0.0', port=8000, log_level='warning')
server = uvicorn.Server(config)

# Inicia o loop de eventos para manter a API no ar
loop = asyncio.get_event_loop()
loop.run_until_complete(server.serve())
```

Endpoint: A API fica imediatamente disponível na rede local em http://localhost:8000.

7.2 Configurações do Servidor

As configurações necessárias para o script correr adequadamente estão inseridas diretamente no código (*hardcoded*) na *string* de conexão ODBC instanciada via pypyodbc.connect(). Os parâmetros mapeados no script incluem:

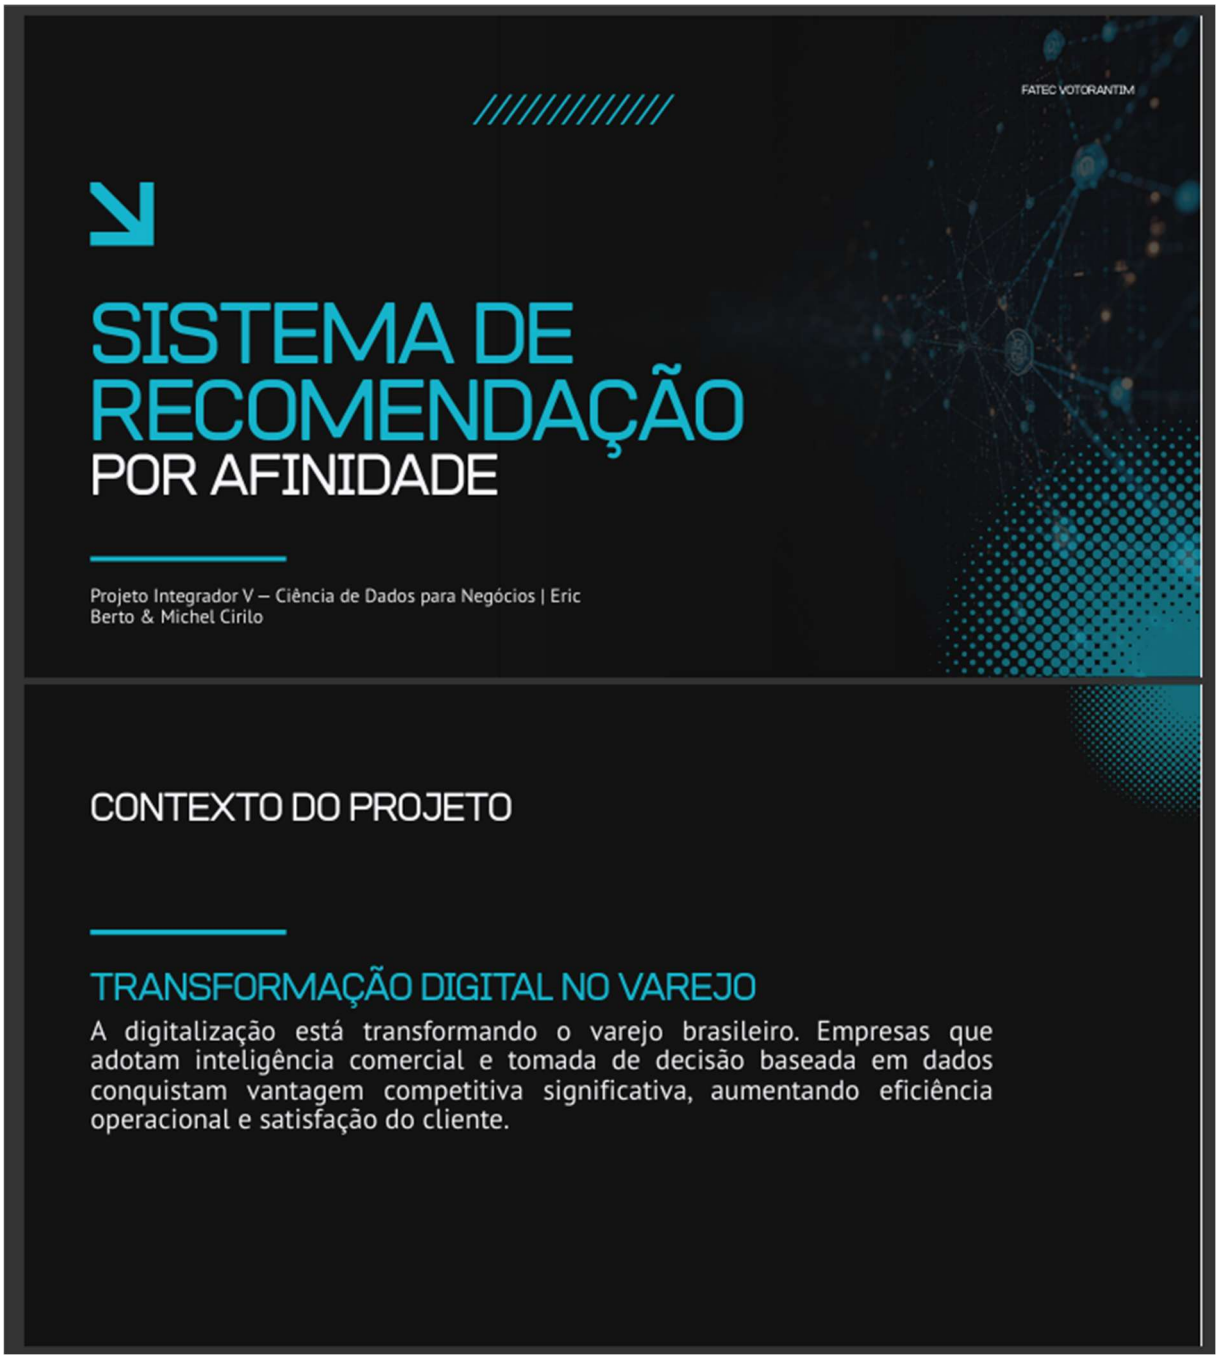
1. Driver HFSQL
2. IP/Servidor Local
3. Porta 4900
4. Nome da Base de Dados
5. Credenciais (UID/PWD)

8. Monitoramento

O acompanhamento da inicialização é feito através das saídas (prints) na consola, embutidas no próprio código, que atestam a integridade da pipeline antes de libertar a porta 8000. As métricas reportadas no terminal são:

- ✅ **Produtos indexados : [Quantidade]**
- ✅ **Mestres mapeados : [Quantidade]**
- ✅ **Regras geradas : [Quantidade]**
- 🚀 **API disponível em: http://localhost:8000**

11.3 Apresentação

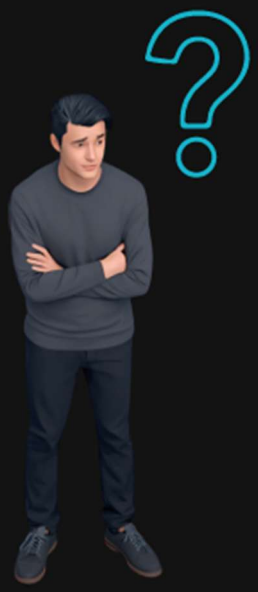


APRESENTAÇÃO DA EMPRESA

BERTO FERRAMENTAS



Loja de médio porte especializada em ferramentas e tintas, localizada em Sorocaba/SP. A empresa busca constantemente inovação e transformação estratégica para se destacar no mercado regional.



PROBLEMA IDENTIFICADO

Desafios do processo atual de vendas que limitam o crescimento e a eficiência operacional da Berto Ferramentas.

- **MEMÓRIA DO VENDEDOR**
  Dependência da experiência individual do vendedor.
- **CROSS-SELLING PERDIDO**
  Oportunidades de venda cruzada desperdiçadas.
- **SEM RECOMENDAÇÕES**
  Ausência de sistema inteligente de sugestões.
- **TICKET MÉDIO ESTAGNADO**
  Dificuldade em aumentar valor por transação.

OBJETIVO DA SOLUÇÃO

BENEFÍCIOS ESTRATÉGICOS

O sistema de recomendação por afinidade transforma o processo de vendas através de inteligência artificial, identificando automaticamente produtos complementares e gerando sugestões em tempo real para maximizar cada oportunidade comercial.

RECOMENDAÇÃO AUTOMÁTICA

Sistema inteligente sugere produtos em tempo real.

CROSS-SELLING PREDITIVO

Identificação de produtos complementares.

TICKET MÉDIO

Aumento significativo do valor por transação.

OTIMIZAÇÃO DO ATENDIMENTO

Vendas mais rápidas e eficientes.

TECNOLOGIAS UTILIZADAS

Stack tecnológica completa para processamento de dados, machine learning e integração com sistemas de vendas.

PYTHON & PANDAS

Manipulação e análise de dados estruturados.

RAPIDFUZZ & MLXTEND

Fuzzy matching e mineração de regras.

API REST & HFSQL

Integração com banco de dados e endpoints.

FP-GROWTH & NLP

Regras de associação e tratamento textual.

ARQUITETURA DA SOLUÇÃO

FLUXO DO SISTEMA

O sistema integra múltiplas camadas tecnológicas para transformar dados brutos em recomendações inteligentes. Desde a extração do banco HFSQL até a entrega via API REST ao sistema de vendas.



BANCO HFSQL

Fonte de dados transacionais da loja.

ML

Pipeline de Modelo/Dados

API REST

Endpoint para consulta de recomendações.

SISTEMA DE RECOMENDAÇÃO

Sistema acessado pelo usuário

PIPELINE DE DADOS

PROCESSAMENTO INTELIGENTE

O fluxo de dados transforma registros brutos em recomendações precisas através de etapas sequenciais de tratamento, padronização e modelagem preditiva com algoritmos de associação.



EXTRAÇÃO

Coleta de dados do banco HFSQL.

LIMPEZA & PLN

Padronização, tratamento textual dos produtos, Regex, Fuzzy.

MODELAGEM

FP-Growth para regras de associação.

RECOMENDAÇÃO

Geração de sugestões de cross-selling.

PLN E TRATAMENTO TEXTUAL

PADRONIZAÇÃO INTELIGENTE

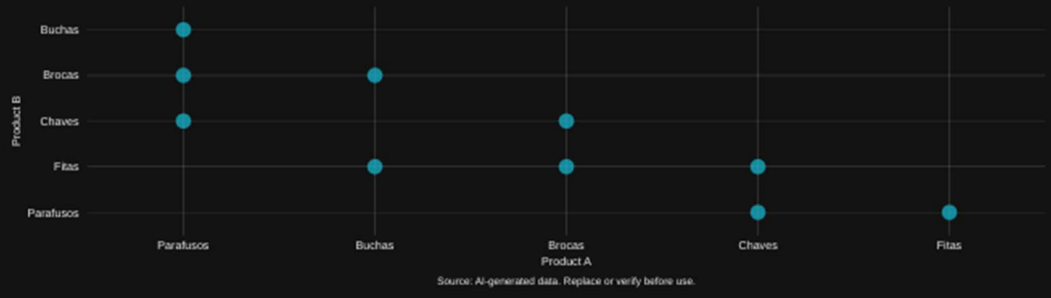
A padronização de nomes de produtos utiliza técnicas avançadas de NLP para corrigir erros de digitação e inconsistências. O agrupamento semântico reduz a dimensionalidade dos dados, permitindo análises mais precisas e recomendações mais eficientes.



MODELAGEM PREDITIVA COM FP-GROWTH

REGRAS DE ASSOCIAÇÃO

O algoritmo FP-Growth identifica padrões de compra através de regras de associação. Support mede a frequência de itens juntos, Confidence indica a probabilidade de compra conjunta, e Lift revela a força da associação entre produtos.



Source: AI-generated data. Replace or verify before use.

RESULTADOS OBTIDOS

KPIS DO PROJETO

Redução de 61,63% na dimensionalidade dos dados, otimizando a performance do modelo de recomendação.

20 MIL REGISTROS

Registros de vendas analisados no projeto.

2.004 REGRAS

Regras de associação geradas pelo modelo.

5 MIL+ SKUS

SKUs tratados e padronizados com NLP.

8.625 VENDAS

Vendas multi-itens analisadas para cross-selling.



INSIGHTS ESTRATÉGICOS

Impactos do sistema de recomendação na operação comercial da Berto Ferramentas.

- **TICKET MÉDIO**
  Potencial aumento com cross-selling preditivo.
- **ATENDIMENTO ÁGIL**
  Redução do esquecimento de itens na venda.
- **GIRO DE ESTOQUE**
  Melhor rotatividade de produtos complementares.
- **INTELIGÊNCIA COMERCIAL**
  Decisões baseadas em dados e padrões de compra.



PRÓXIMOS PASSOS

ROADMAP DE EVOLUÇÃO

Planejamento estratégico para implementação e expansão contínua do sistema de recomendação.

DEPLOY REAL

Implementação da solução em ambiente de produção.

INTEGRAÇÃO EM TEMPO REAL

Conexão direta com sistema de vendas.

TESTES PILOTO

Validação com usuários reais e calibração do modelo.

EXPANSÃO IA

Novas funcionalidades de inteligência artificial e machine learning.

CONCLUSÃO

O projeto transforma dados em inteligência comercial, aproximando a Berto Ferramentas de uma operação orientada por IA e decisões preditivas. A solução desenvolvida demonstra como ciência de dados pode gerar valor real para o varejo, otimizando vendas e impulsionando resultados estratégicos.